ĐẠI HỌC BÁCH KHOA HÀ NỘI



PROJECT III

Kriky

Trợ lí hỗ trợ giáo viên ra đề và chữa bài

Giảng viên hướng dẫn: Vũ Văn Thiệu

Sinh viên thực hiện: Lê Nguyễn Phước Thành – 20235561

Mục lục

1 Đặt vấn đề **5**
- 1.1 Bối cảnh . . . 5
- 1.2 Vấn đề cần giải quyết . . . 7
- 1.3 Mục tiêu sản phẩm . . . 7
- 1.4 Phạm vi . . . 7

2 Ý tưởng sản phẩm **8**
- 2.1 Luồng tổng thể . . . 8
- 2.2 Hai giai đoạn làm bài của học sinh . . . 10
- 2.3 Làm sao phân tích lỗi của học sinh? . . . 10
- 2.4 Tạo câu hỏi mới dựa trên câu làm sai . . . 10
- 2.5 Thang điểm . . . 10
- 2.6 Giáo viên đưa ra quyết định ở đâu? . . . 11

3 Actor và khái niệm nghiệp vụ **12**
- 3.1 Hai actor . . . 12
  - 3.1.1 Teacher . . . 12
  - 3.1.2 Student . . . 12
- 3.2 Từ điển khái niệm . . . 12
  - 3.2.1 Người dùng, đề và bài làm . . . 12
  - 3.2.2 Thành phần hệ thống . . . 13
  - 3.2.3 Tài liệu . . . 14
  - 3.2.4 Trợ lí . . . 14

4 Các luồng nghiệp vụ **16**
- 4.1 Workflow 1 — Tạo và duyệt đề . . . 18
- 4.2 Workflow 2 — Làm bài (giai đoạn 1) . . . 18
- 4.3 Workflow 3 — Chấm bài . . . 18
- 4.4 Workflow 4 — Chữa bài (giai đoạn 2) . . . 19
  - 4.4.1 Giai đoạn 2 đếm giờ như thế nào? . . . 19
  - 4.4.2 Khi nào kết thúc giai đoạn 2 . . . 19
  - 4.4.3 Giáo viên làm gì? . . . 20
- 4.5 Business Workflows . . . 20

5 Use case **21**
- 5.1 Sáu use case . . . 21
- 5.2 Đặc tả từng use case . . . 23
  - 5.2.1 UC-01 — Tạo đề nháp . . . 23

5.2.2 UC-02 — Review và phát hành đề . . . 23
5.2.3 UC-03 — Làm và nộp bài . . . 23
5.2.4 UC-04 — Chữa bài . . . 23
5.2.5 UC-05 — Tạo câu biến thể . . . 24
5.2.6 UC-06 — Báo cáo Trợ lí giải thích chưa rõ . . . 24

6 Kiến trúc và mô hình dữ liệu 25
6.1 Các service trong hệ thống . . . 25
6.2 Frontend không nhìn thấy bên trong hệ thống . . . 27
6.3 Backend quyết định mọi thứ . . . 27
6.4 Service nào kết nối tới store nào? . . . 27
6.5 Các service nói chuyện với nhau thế nào . . . 28
6.6 Job nào đi qua queue, job nào không . . . 28
6.7 Nếu một service ngừng thì mất gì? . . . 30
6.8 Mô hình dữ liệu . . . 31

7 Chi tiết các service 34
7.1 Backend . . . 34
7.1.1 Vai trò và trách nhiệm . . . 34
7.1.2 Giao job, lấy kết quả và gửi event . . . 35
7.1.3 Xử lý các nghiệp vụ chính . . . 36
7.1.4 Xử lý lỗi . . . 44
7.1.5 Toàn cảnh một lượt hội thoại của giáo viên . . . 45
7.2 Agent . . . 46
7.2.1 Vai trò và trách nhiệm . . . 46
7.2.2 Nhận job, gọi mô hình và trả kết quả . . . 47
7.2.3 Xử lý các task chính . . . 48
7.2.4 Các ràng buộc và cơ chế kiểm soát . . . 51
7.2.5 Xử lý lỗi . . . 52
7.2.6 Các giới hạn hiện tại . . . 53
7.3 Document . . . 53
7.3.1 Vai trò và trách nhiệm . . . 53
7.3.2 Hai worker, ba task và sáu collection . . . 54
7.3.3 Một tệp đi qua service . . . 55
7.3.4 Các ràng buộc và cơ chế kiểm soát . . . 57
7.3.5 Xử lý lỗi . . . 59
7.3.6 Các giới hạn hiện tại . . . 60

Tài liệu tham khảo 62

Danh mục hình vẽ

1.1 Domain Context 6

2.1 Tổng thể một vòng 9

4.1 Activity Overview 17
4.2 Business Workflows 20

5.1 Use Case Diagram 22

6.1 System Architecture 26
6.2 Tải lên một tài liệu 29

7.1 Pha đề xuất của một lượt hội thoại 37
7.2 Kiểm một plan trước khi thực thi 39
7.3 Pha thực thi của một lượt hội thoại 40
7.4 Đời một câu hỏi của đề 41
7.5 Nộp bài và giai đoạn 2 43
7.6 Một lượt hội thoại của giáo viên 46
7.7 Ba tầng của đề xuất 50
7.8 Một tệp đi qua `document` 56
7.9 Báo hỏng oan khi đọc nhiều cuốn cùng lúc 61

Danh mục bảng

2.1 Ba mức điểm của một câu hỏi 11

5.1 Sáu use case và actor chính của từng cái 21

6.1 Năm service của hệ thống 25
6.2 Service nào đọc, ghi store nào 27
6.3 Sáu task gọi Model Provider 30
6.4 Mỗi service ngừng thì mất gì, còn gì 31
6.5 Hai mươi hai bảng dữ liệu 31

7.1 Ba cách nhận kết quả từ `agent` 35
7.2 Các thao tác trên đề 42
7.3 Cơ chế xử lý lỗi của `backend` 44
7.4 Năm task của `agent` 47
7.5 Ràng buộc `agent` giữ 51
7.6 Khi một thao tác của `agent` hỏng 52
7.7 Ba task của `document` 54
7.8 Sáu collection của content store 55
7.9 Bảy hàm dựng cây mục lục 57
7.10 Ràng buộc `document` giữ 58
7.11 Khi một thao tác của `document` hỏng 59

Chương 1

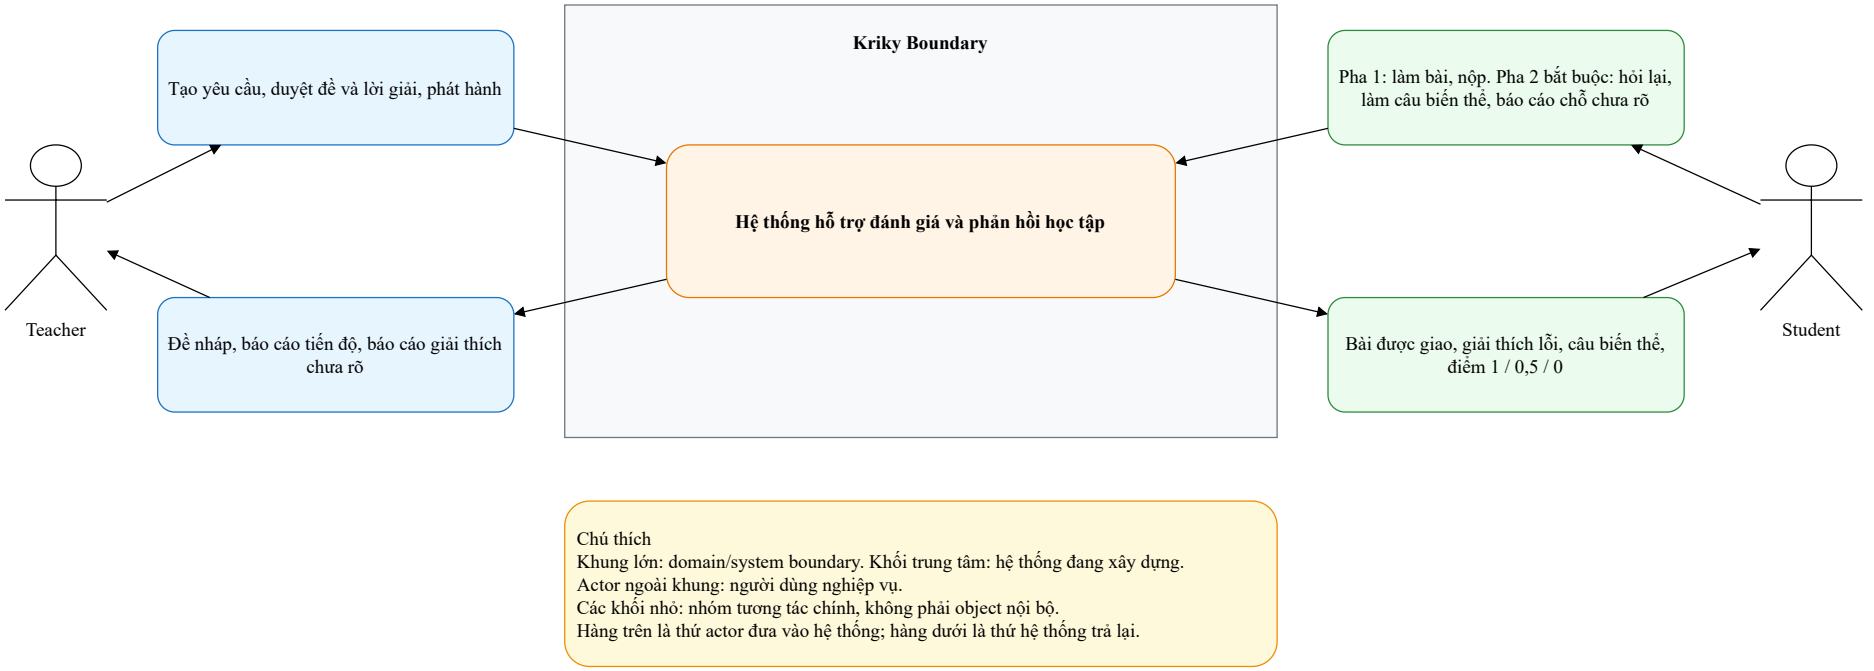
Đặt vấn đề

1.1 Bối cảnh

Ở trường phổ thông, một bài kiểm tra thường kết thúc khi giáo viên trả điểm. Học sinh nhận lại bài, nhìn những câu bị gạch chéo, rồi phần lớn dừng ở đó. Thứ thực sự làm thay đổi kết quả học tập là việc hiểu ra mình sai ở đâu và làm lại được, nhưng việc đó hiếm khi xảy ra, vì nó cần một cuộc trao đổi riêng cho từng em về từng câu.

Giáo viên không phải không muốn làm. Vấn đề nằm ở khối lượng công việc. Một lớp bốn mươi học sinh làm một đề mười câu sẽ sinh ra bốn trăm lượt trả lời, và mỗi lượt sai có thể sai vì một lý do khác nhau. Giải thích riêng cho từng em, rồi ra thêm một câu tương tự để kiểm xem em đã sửa được chưa, là công việc tăng theo sĩ số và không có cách nào rút gọn.

Kriky là hệ thống được xây để gánh phần công việc đó, nhưng không lấy đi quyền quyết định của giáo viên. Hình 1.1 cho thấy ranh giới của hệ thống: hai **actor** (tác nhân, mục 3.2) ở hai phía, cùng những gì đi vào và đi ra.



Hình 1.1: Domain Context — ranh giới hệ thống, hai actor, và những gì đi qua ranh giới ấy

1.2 Vấn đề cần giải quyết

Phần tốn thời gian nhất của giáo viên không phải là gõ ra đề bài, mà là năm việc sau. Cả năm đều là công việc chuyên môn:

- Soạn đề bám đúng mục tiêu học tập, thay vì gom câu hỏi cho đủ số lượng.
- Tạo phương án nhiễu có ý nghĩa. Một phương án sai ngẫu nhiên không nói lên điều gì, còn một phương án nhiễu tốt là phương án mà học sinh mắc một lỗi cụ thể sẽ chọn.
- Chấm bài và viết nhận xét cho từng học sinh.
- Phân định học sinh sai vì thiếu kiến thức, vì suy luận hỏng, vì tính nhầm, hay vì hiểu sai một khái niệm.
- Ra câu biến thể của đúng câu học sinh vừa làm sai, để kiểm xem em đã sửa được chỗ sai đó hay chỉ nhớ được đáp án.

Phía học sinh, nhu cầu ngược lại nhưng khớp vào: phản hồi cần đến nhanh, và bài luyện tập cần đúng với điểm yếu của riêng mình. Một phản hồi đúng nhưng đến sau hai tuần thì không còn tác dụng, vì học sinh đã quên mình nghĩ gì lúc làm bài.

1.3 Mục tiêu sản phẩm

Hệ thống hướng tới ba mục tiêu nghiệp vụ:

1. Hỗ trợ giáo viên tạo đề từ một yêu cầu bằng ngôn ngữ tự nhiên. Một đề có hai nguồn câu hỏi: nội dung sinh mới, và **Question Bank** (ngân hàng câu hỏi, mục 3.2).
2. Phân tích lỗi sai hoặc hiểu nhầm khái niệm của học sinh thông qua cuộc trò chuyện thay vì một câu nhận xét.
3. Tạo các câu hỏi mới từ các câu mà học sinh làm sai ngay trong cùng bài kiểm tra.

1.4 Phạm vi

Hệ thống dựng trọn một vòng nghiệp vụ, từ đầu đến cuối:

- Giáo viên tạo, xem lại và phát hành đề. Việc duyệt bao gồm cả lời giải và ánh xạ từ phương án nhiễu sang lỗi, không chỉ câu hỏi và đáp án.
- Giai đoạn 1: Học sinh làm bài, nộp bài, và hệ thống chấm bài để biết học sinh đang thiếu kiến thức ở phần nào.
- Giai đoạn 2: Học sinh trò chuyện với trợ lí Kriky để hiểu cách làm bài và tại sao lại sai. Sau đó hệ thống tạo câu hỏi mới, học sinh làm lại cho tới khi hiểu được cách làm của dạng bài.

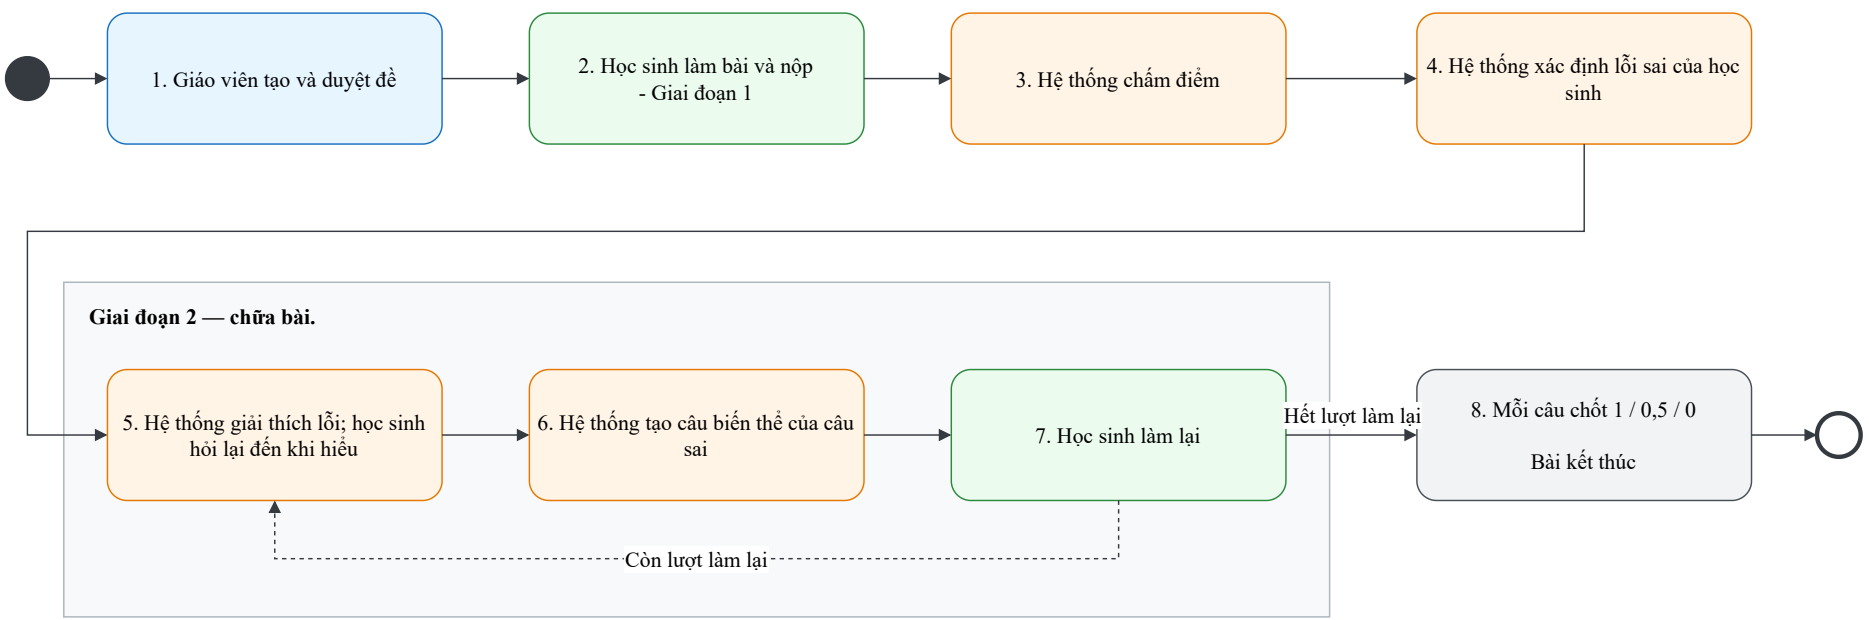
Chương 2

Ý tưởng sản phẩm

2.1 Luồng tổng thể

Ý tưởng lõi không nằm ở việc sinh câu hỏi, mà ở việc khép kín một vòng tám bước:

1. Giáo viên tạo và duyệt đề.
2. Học sinh làm bài.
3. Hệ thống chấm điểm.
4. Hệ thống xác định lỗi sai của học sinh.
5. Hệ thống giải thích lỗi, học sinh hỏi lại đến khi hiểu.
6. Hệ thống tạo câu biến thể của câu sai.
7. Học sinh làm lại.
8. Mỗi câu chốt ở một trong ba mức điểm, và bài kết thúc.



Hình 2.1: Tổng thể một vòng

2.2 Hai giai đoạn làm bài của học sinh

Bước 2, 7 và 8 của hình 2.1.

Một bài kiểm tra có hai giai đoạn: giai đoạn 1 là làm bài và nộp, giai đoạn 2 là chữa những câu đã sai. Nộp bài kết thúc giai đoạn 1 chứ không kết thúc bài. Bài chỉ kết thúc khi giai đoạn 2 xong, hoặc khi hạn của giai đoạn 2 hết.

Kéo theo đó là một hệ quả cần nói rõ: một bài kiểm tra có hai trạng thái hoàn thành khác nhau, *đã nộp* và *đã hoàn thành*, và chúng không thay thế cho nhau được.

2.3 Làm sao phân tích lỗi của học sinh?

Bước 4 của hình 2.1.

Với hình thức trắc nghiệm, việc chấm chỉ là một phép so. Khó khăn nằm ở chẩn đoán lỗi sai của học sinh, bởi cùng chọn một phương án sai có thể do nhiều lỗi khác nhau sinh ra. Nếu hệ thống đoán lỗi rồi đi giải thích một lỗi học sinh không hề mắc thì nó còn tệ hơn im lặng: em vừa mất thời gian, vừa được dạy sai chỗ.

Vì vậy, mỗi phương án sai phải mang theo lỗi mà nó đại diện, và được soạn cùng câu hỏi chứ không suy ra lúc chấm.

Hai luật đi kèm:

- Mỗi câu hỏi phải mang theo lời giải có nhiều hơn một cách làm.
- Số phương án không cố định. Một câu có thể có ba, bốn hay năm lựa chọn tuỳ từng câu, nhưng chỉ đúng một lựa chọn là đáp án đúng. Mọi phương án còn lại đều là nhiễu, nên đều phải có lỗi gắn kèm.

2.4 Tạo câu hỏi mới dựa trên câu làm sai

Bước 6 và 7 của hình 2.1

Khi học sinh sai câu 3, hệ thống sinh câu 3̀, gọi là câu biến thể. Thứ cần chữa là một lỗi cụ thể vừa xảy ra, không phải một chủ đề.

Câu biến thể giữ nguyên dạng đề và cách làm, chỉ đổi dữ kiện, con số và cách hỏi. Đó là cách duy nhất kiểm được rằng học sinh đã sửa đúng chỗ mình sai, chứ không phải chỉ nhớ được đáp án.

2.5 Thang điểm

Bước 8 của hình 2.1.

Ba mức thay vì hai, vì hai mức sẽ biến việc chữa bài thành công việc không được có ý nghĩa. Một học sinh sửa được lỗi của mình đã học đúng thứ mà bài kiểm tra muốn dạy, và mức giữa là chỗ duy nhất ghi nhận điều đó. Vì vậy giai đoạn 2 chỉ cộng chứ không bao giờ trừ: điểm tính ngay sau khi nộp là sàn.

Bảng 2.1: Ba mức điểm của một câu hỏi

Điểm	Nghĩa
1	Đúng ngay ở giai đoạn 1
0,5	Sai ở giai đoạn 1 nhưng chữa được ở giai đoạn 2
0	Sai và không chữa được

2.6 Giáo viên đưa ra quyết định ở đâu?

Bước 1 của hình 2.1.

Với nội dung đề, trợ lí viết còn giáo viên quyết nội dung đó có đến tay học sinh hay không. Giáo viên bắt buộc tham gia ở hai điểm, một ở đầu ra và một ở đầu vào:

1. Trợ lí hỏi lại khi chưa đủ thông tin, thay vì tự đoán (đầu vào).
2. Duyệt đề trước khi phát hành (đầu ra).

Chương 3

Actor và khái niệm nghiệp vụ

3.1 Hai actor

Hệ thống có đúng hai **actor** (tác nhân) nghiệp vụ: **Teacher** (giáo viên) và **Student** (học sinh).

3.1.1 Teacher

Teacher là người đưa ra các quyết định. Teacher có thể:

- Nhập yêu cầu tạo đề.
- Xem và chỉnh sửa đề do trợ lí tạo.
- Duyệt đề trước khi phát hành.
- Phát hành đề cho một hoặc nhiều lớp.
- Xem kết quả làm bài của học sinh.
- Xem báo cáo học sinh gửi về chỗ trợ lí giải thích chưa rõ.

3.1.2 Student

Student là người nhận đề, làm bài và luyện tập. Student có thể:

- Xem bài kiểm tra được giao.
- Chọn đáp án và nộp bài (giai đoạn 1).
- Nghe giải thích lỗi và hỏi lại đến khi hiểu (giai đoạn 2).
- Làm câu biến thể của những câu đã sai (giai đoạn 2).
- Báo cáo chỗ trợ lí giải thích chưa rõ.

3.2 Từ điển khái niệm

3.2.1 Người dùng, đề và bài làm

- **Actor**: Hệ thống có hai actor: *Teacher* là giáo viên, *Student* là học sinh. Báo cáo chỉ dùng hai chữ tiếng Anh này khi nói về actor và trong sơ đồ; khi kể thì gọi là giáo viên, học sinh.
- **Use case**: Một chức năng hệ thống mang lại cho actor.
- **Workflow**: Luồng nghiệp vụ, tức chuỗi hoạt động mà các actor và hệ thống lần lượt làm để đạt một mục tiêu, như tạo và duyệt một đề. Một workflow có thể gồm nhiều use case.

- **Assessment**: Bài kiểm tra, hay bộ câu hỏi được giao cho học sinh.
- **Question**: Câu hỏi trong một assessment.
- **Distractor**: Phương án sai *có chủ đích*, đại diện cho một lỗi hoặc một hiểu nhầm cụ thể. Không phải đáp án nhiễu ngẫu nhiên.
- **Lời giải**: Cách làm đi kèm mỗi câu hỏi, bắt buộc có nhiều hơn một cách. Trợ lí dựa vào lời giải để giải thích cho học sinh.
- **Draft**: Đề đang soạn, chưa duyệt. Câu hỏi ở trạng thái này sửa và xoá được tự do.
- **Approve**: Chốt rằng đề đã dùng được. Đây là một *trạng thái*, không phải một thao tác: nó có cả chiều ngược, gọi là *unapprove*, và chỉ đề đã approve mới phát hành được.
- **Question Bank**: Ngân hàng câu hỏi riêng của từng giáo viên.
- **Class**: Lớp học có sẵn danh sách học sinh. Giáo viên tạo lớp. Phát hành đề phải chọn một lớp đã tạo từ trước.
- **Publish** và **Publication**: *Publish* là phát hành một đề cho một lớp. Một *Publication* là bản ghi sinh ra từ việc đó.
- **Giai đoạn 1**: Phần làm bài và nộp.
- **Giai đoạn 2**: Phần chữa bài.
- **opens_at** / **closes_at** / **remediation_deadline**: Ba mốc thời gian của một *Publication*. Hai mốc đầu là thời điểm mở và đóng giai đoạn 1; mốc thứ ba là thời điểm đóng giai đoạn 2.
- **Submission**: Việc nộp bài, và là mốc kết thúc *giai đoạn 1* — không phải mốc kết thúc bài kiểm tra.
- **Attempt**: Một lần làm bài của một học sinh trên một đề, trải qua **cả hai giai đoạn**. Mỗi học sinh có duy nhất một Attempt cho mỗi đề — em chưa vào làm thì không có Attempt nào. Nó xong khi giai đoạn 2 hoàn thành.
- **Mark** và **Score**: *Mark* là điểm của *một câu*; *score* là điểm của *cả bài*.
- **Misconception**: Hiểu nhầm khái niệm, hoặc lỗi sai có tính lặp lại.
- **Feedback**: Phản hồi / nhận xét của trợ lí cho những thắc mắc của học sinh.
- **Lượt**: Một lượt cho phép học sinh làm lại các câu sai của giai đoạn trước / lượt trước. Khác với một *lượt hội thoại*: một tin nhắn cùng mọi thứ trợ lí làm để đáp lại tin ấy.
- **Câu biến thể**: Câu sinh từ *câu học sinh làm sai ở giai đoạn 1*: giữ cấu trúc và lỗi cần kiểm, chỉ đổi dữ kiện.

3.2.2 Thành phần hệ thống

- **Service**: Một đơn vị chạy độc lập trong hệ thống. Hiện tại có năm service: `frontend`, `backend`, `agent`, `document`, `ingest`.
- **API** (Application Programming Interface): Giao diện lập trình, tức cách một chương trình gọi một chương trình khác. Giữa các service, chỉ `frontend` gọi `backend` theo cách này; các service nội bộ không gọi API để giao tiếp với nhau.
- **Gateway**: `backend` là gateway của cả hệ thống: không màn hình nào của `frontend` gọi thẳng `agent`, `document` hay `ingest`.
- **VPC** và **Subnet**: *VPC* là đám mây riêng ảo, tức một vùng mạng riêng tách khỏi bên ngoài; nó chứa mọi service trừ `frontend`. Nó chia thành các *subnet*, tức các vùng mạng con: chỉ những gì nằm ở *public subnet* (vùng mạng công khai) mới nhận được kết nối từ bên ngoài, còn những gì nằm ở *private subnet* (vùng mạng nội bộ) thì không. Hình kiến trúc ở chương 6 đặt `backend` ở public subnet, mọi service và kho khác ở private subnet.
- **Job** và **Task**: Hai thứ khác nhau. Một *task* là *tên* của một loại việc. Một *job* là một lần chạy của task ấy, mỗi job có một mã riêng.
- **Queue**: Nơi một service đẩy job vào và một service khác lấy ra làm. Job nằm lại trên queue

đến khi có ai lấy, nên tắt máy giữa chừng không mất việc.
- **Worker**: Tiến trình ngồi nghe một queue, lấy job xuống và chạy. Nó không nhận lời gọi từ ngoài; thứ duy nhất nó đọc là queue. Một service có thể có nhiều worker: `document` có một worker đọc chữ của tệp và một worker dựng cây mục lục.
- **Byte**: Đơn vị cơ bản để đo và lưu dữ liệu trong máy; mọi tệp, dù là PDF hay ảnh chụp, đều là một dãy byte. Báo cáo nói *byte của tệp*, tức dữ liệu gốc, để chỉ chính tệp giáo viên tải lên, nguyên như lúc tải, khác với chữ hệ thống đọc ra từ nó.
- **Store**: Kho dữ liệu mà service đọc và ghi. Hệ thống có bốn store thuộc bốn loại khác nhau, nên mỗi loại mang chữ riêng: *database* giữ dữ liệu có cấu trúc, *object store* giữ byte của tệp, *content store* giữ nội dung đã xử lí của tài liệu, như chữ từng trang và cây mục lục, và *queue* giữ job đang chờ.
- **Collection**: Nhóm bản ghi cùng loại trong content store, giống một bảng của database.
- **Credential**: Khoá cho phép một service vào một store để đọc / ghi.
- **Pub/sub** và **Channel**: *Pub/sub* là cách một service phát tin lên một *channel*, tức một kênh có tên: ai đang nghe channel ấy thì nhận, ai không nghe thì mất. Khác queue ở chỗ nó **không giữ lịch sử**, nên hệ thống chỉ phát qua nó những thứ mất được.
- **SSE** và **Polling**: Hai cách để màn hình cập nhật thời gian thực (realtime). Với *SSE*, `backend` giữ một kết nối mở và gửi tin xuống qua đó mỗi khi có gì đổi. Với *polling*, màn hình tự hỏi lại theo một chu kì. Hệ thống hiện tại dùng *SSE*.
- **Event**: Một tin `backend` gửi xuống màn hình qua SSE.

3.2.3 Tài liệu

Nhóm này đi theo một tài liệu, từ tệp giáo viên tải lên tới những mẩu chữ trợ lí đọc:

- **Document**: Tài liệu giáo viên tải lên, là một tệp PDF hoặc tệp chữ thuần `.txt`, `.md`. Nó nằm trong kho lưu trữ riêng của từng tài khoản, cung cấp kiến thức và giới hạn phạm vi ra đề. Một tài liệu chỉ dùng được khi hệ thống đã đọc ra chữ của nó, kể cả đọc từ ảnh nếu tệp là bản chụp, và đã dựng xong *cây mục lục*.
- **OCR** (Optical Character Recognition): Đọc chữ từ ảnh trong tài liệu.
- **Bản thô**: Những gì `document` đọc được từ một tệp, chia theo trang và theo khối chữ, trước khi có cây mục lục. Bản thô được ghi vào content store trước, rồi cây mục lục mới được dựng từ nó.
- **Cây mục lục**: Mục lục của một *Document* mà hệ thống tự dựng từ nội dung của tệp. Cây có tối đa ba cấp, ví dụ: chương, bài và mục.
- **Chunk**: Một mẩu chữ ngắn cắt từ bản thô, thường thuộc về đúng một nút của cây mục lục. Khi trợ lí cần đọc một bài của tài liệu, `backend` lấy các chunk của bài ấy và các mục bên dưới đưa cho nó, chứ không đưa cả tài liệu.
- **Scope**: Phạm vi ra đề trong một *Document*: các nút giáo viên chọn trên cây mục lục, như một chương hay vài bài, cùng mọi mục nằm dưới chúng. Scope trỏ vào nút, không trỏ vào số trang.

3.2.4 Trợ lí

- **Model Provider**: Nhà cung cấp mô hình ngôn ngữ, nằm ngoài hệ thống. Chỉ hai service gọi tới nó: `agent`, để soạn câu và trò chuyện, và `document`, khi dựng cây mục lục.
- **Tool**: Một việc có tên mà `agent` được phép *đề xuất* chạy, kèm tham số. Có tool tra cứu, như xem lớp, xem kết quả của một đề, đọc mục lục và chữ của tài liệu; và tool ghi, như mở đề, soạn câu, thay một câu. Danh sách tool là một **ràng buộc**, không phải một tiện ích:

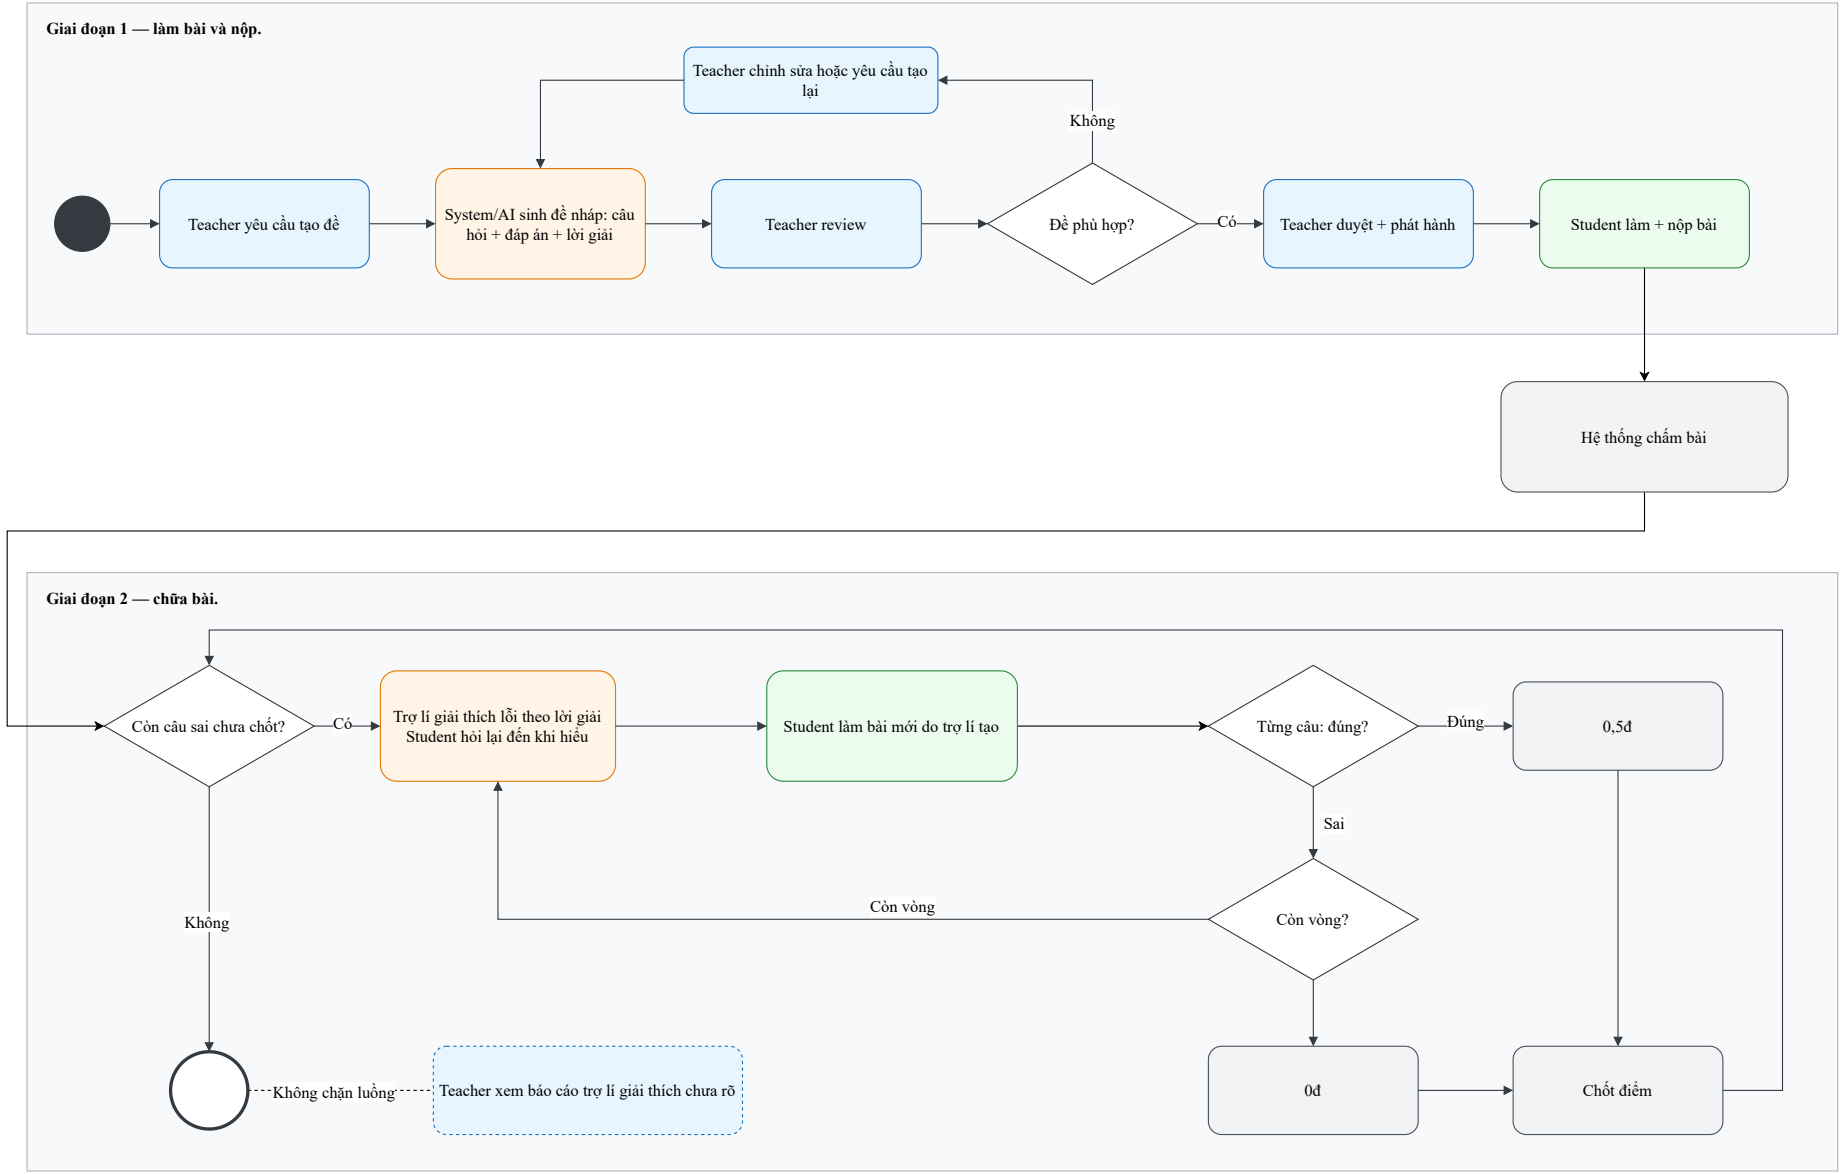
duyệt đề và phát hành đề cố ý không có tool nào, nên `agent` không có đường nào để đề xuất chúng.

- **Dàn ý**: Kế hoạch của một đề mà trợ lí đưa ra *trước* khi soạn câu nào. Mỗi mục của dàn ý nói mục ấy có mấy câu, kiểm kiến thức gì, dùng công thức nào, làm bài theo cách nào, và dựa vào bài nào của tài liệu nếu có. Giáo viên đồng ý thì câu hỏi mới được soạn.
- **Plan**: Danh sách việc trợ lí định làm cho một tin nhắn của giáo viên, mỗi việc là một *tool* kèm tham số.
- **Graph**: Cách `agent` và `document` tổ chức một job có gọi mô hình: một chuỗi các hàm cố định, dựng bằng thư viện LangGraph. Mỗi hàm làm một phần rồi trao kết quả cho hàm sau; chuỗi có thể quay lại một hàm trước, như khi hàm viết câu hỏi không qua được hàm kiểm tra và phải viết lại.

Chương 4

Các luồng nghiệp vụ

Nghiệp vụ của hệ thống gồm bốn luồng. Hình 4.1 và hình 2.1 mô tả cùng một luồng, nhưng ở hai mức chi tiết khác nhau.



Hình 4.1: Activity Overview — toàn bộ vòng, hai giai đoạn nằm trong hai khung riêng

4.1 Workflow 1 — Tạo và duyệt đề

Mục tiêu. Giúp giáo viên tạo được đề phù hợp với mục tiêu học tập, nhưng giáo viên vẫn là người duyệt cuối cùng trước khi phát hành.

Luồng chính.

1. **Teacher** (giáo viên) nhập yêu cầu tạo đề.
2. Teacher cung cấp ràng buộc: chủ đề, độ khó, số lượng câu hỏi, loại bài kiểm tra, thời gian làm bài.
3. `System/AI` phân tích yêu cầu.
4. `System/AI` tạo đề nháp gồm câu hỏi, phương án trả lời, đáp án đúng, lời giải và **metadata** (thông tin mô tả) cơ bản.
5. Teacher xem đề nháp.
6. Teacher chỉnh sửa thủ công, hoặc yêu cầu tạo lại một phần.
7. Teacher duyệt đề.
8. Teacher phát hành đề cho **Student** (học sinh).

Điểm kiểm soát. Teacher phải duyệt đề trước khi đề được phát hành. Đề kiểm tra ảnh hưởng trực tiếp đến việc đánh giá học sinh, nên trợ lí không được tự phát hành.

4.2 Workflow 2 — Làm bài (giai đoạn 1)

Mục tiêu. Cho phép học sinh làm bài và ghi nhận bài nộp để hệ thống đánh giá.

Luồng chính.

1. Student nhận **assessment** (bài kiểm tra) đã được Teacher phát hành.
2. Student vào làm, *tới hết* giờ đóng.
3. Student trả lời câu hỏi trắc nghiệm.
4. Student nộp bài.
5. Hệ thống ghi nhận **submission** (việc nộp bài) để đánh giá.

Ba tham số thời gian. Giai đoạn 1 có ba tham số thời gian độc lập: thời gian làm bài (`phase1_minutes`), giờ mở (`opens_at`) và giờ đóng (`closes_at`).

Luật là: giờ đóng chặn việc *vào làm*, không chặn việc nộp. Học sinh vào tới hết giờ đóng vẫn được. Ai đã vào rồi thì không bị dừng giữa chừng, và được đủ thời gian làm bài kể cả khi tràn qua giờ đóng. Ví dụ, đóng lúc 18:00 với thời gian làm bài 15 phút thì bài cuối có thể nộp lúc 18:15.

4.3 Workflow 3 — Chấm bài

Mục tiêu. Biết được những câu mà học sinh làm sai, từ đó trả lời các thắc mắc của học sinh thông qua cuộc trò chuyện và tạo ra các câu hỏi biến thể để kiểm tra độ hiểu bài.

Luồng chính.

1. Học sinh nộp bài.
2. Hệ thống **so** phương án đã chọn với đáp án đúng của câu hỏi đã duyệt. Đây là một phép so, không phải một phán đoán — nên không có gì để mà không chắc.
3. Điểm giai đoạn 1 chốt ngay và học sinh thấy ngay.

Hai điều kiện phải có sẵn từ lúc duyệt đề.

- Mỗi phương án nhiễu phải đại diện cho một lỗi cụ thể, soạn cùng lúc với câu hỏi. Phương án nhiễu mà không đại diện cho một lỗi cụ thể thì không giúp học sinh tiến bộ.
- Mỗi câu hỏi phải kèm lời giải. Việc chấm không dùng tới nó, nhưng phương án nhiễu phải được tạo dựa trên lời giải thì mới có ý nghĩa và trợ lí phải dựa vào lời giải để giải thích cho học sinh chứ không tự nghĩ ra cách giải mới. Chính vì thế lời giải phải tồn tại từ lúc duyệt đề chứ không sinh ra lúc học sinh hỏi.

4.4 Workflow 4 — Chữa bài (giai đoạn 2)

Mục tiêu. Bài kiểm tra chỉ kết thúc khi học sinh hiểu bài và sửa được lỗi họ mắc phải.

Luồng chính.

1. Học sinh trò chuyện với trợ lí Kriky về lỗi sai, chỗ nào chưa hiểu, cách giải như thế nào.
2. Kriky dựa vào *lời giải đã soạn kèm câu hỏi*. Học sinh hỏi lại đến khi hiểu. Phần này **không tính giờ**.
3. Trong lúc đó, hệ thống sinh câu biến thể của câu mà học sinh làm sai.
4. Học sinh bấm nút làm bài mới. Đồng hồ của lượt bắt đầu chạy.
5. Học sinh làm các câu mới trong lượt.
6. Câu nào đúng thì chốt **0,5** điểm; câu nào còn sai thì sang vòng tiếp.
7. Mỗi câu tối đa **ba vòng**. Hết ba vòng mà vẫn sai thì chốt **0** điểm.
8. Bài kết thúc khi mọi câu đã chốt, hoặc khi hết hạn giai đoạn 2.

4.4.1 Giai đoạn 2 đếm giờ như thế nào?

Giai đoạn 2 nhận hai tham số: số phút mỗi câu (`phase2_minutes_per_question`), và hạn kết thúc giai đoạn 2 (`remediation_deadline`).

Thời lượng của một lượt bằng số phút mỗi câu nhân với số câu còn sai trong lượt đó, nên sai hai câu với thời lượng làm lại 5 phút mỗi câu thì lượt ấy dài 10 phút.

Phần giải thích không tính giờ. Đồng hồ chỉ bắt đầu khi học sinh tự bấm nút làm bài mới.

4.4.2 Khi nào kết thúc giai đoạn 2

Hạn kết thúc giai đoạn 2 là một mốc tuyệt đối do giáo viên đặt, chung cho cả lớp, và dài hơn hẳn hạn của giai đoạn 1, chẳng hạn là cuối ngày.

Hết hạn thì dừng, kể cả khi học sinh đang làm dở một lượt, và câu chưa xong nhận 0 điểm.

Đây là chỗ giai đoạn 2 làm ngược với giai đoạn 1. Ở giai đoạn 1, học sinh đã vào thì không bị dừng giữa chừng; ở giai đoạn 2, hết hạn là dừng. Hai luật nghịch nhau một cách có chủ ý:

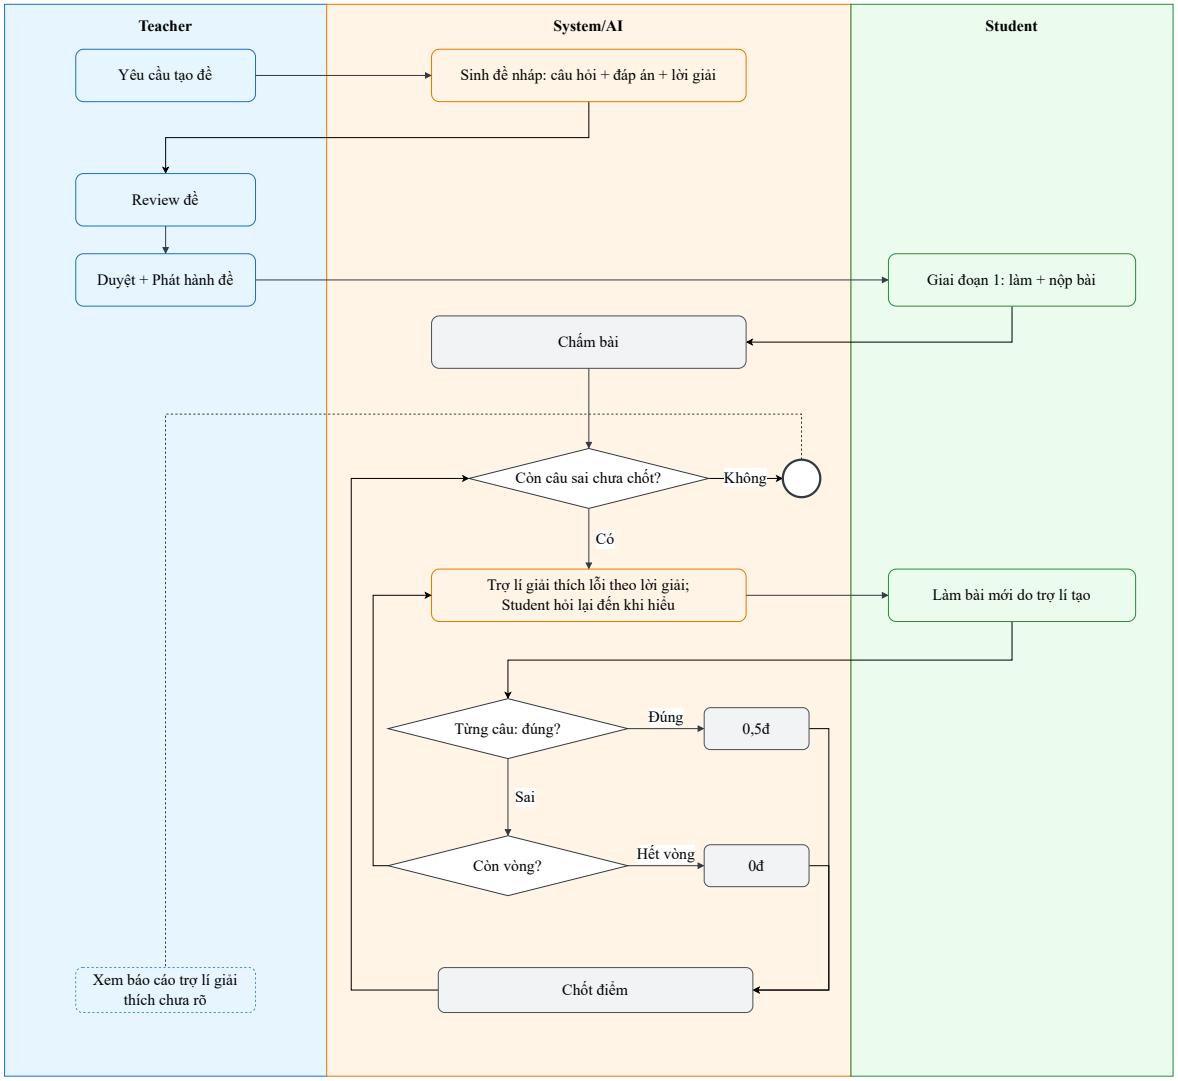
thời gian ở giai đoạn 1 là một lượng hệ thống cấp cho từng người kể từ lúc em vào, còn hạn của giai đoạn 2 là một mốc chung cả lớp nhìn thấy suốt ngày — không cắt thì mốc ấy không tồn tại.

4.4.3 Giáo viên làm gì?

Học sinh báo cáo một câu hoặc một đoạn hội thoại là *giải thích chưa rõ*. Giáo viên xem được các báo cáo này và giải thích để đưa vào bài dạy trên lớp.

4.5 Business Workflows

Hình 4.1 cho thấy luồng tổng quan; hình 4.2 cho thấy trách nhiệm của từng vị trí.



Hình 4.2: Business Workflows

Chương 5

Use case

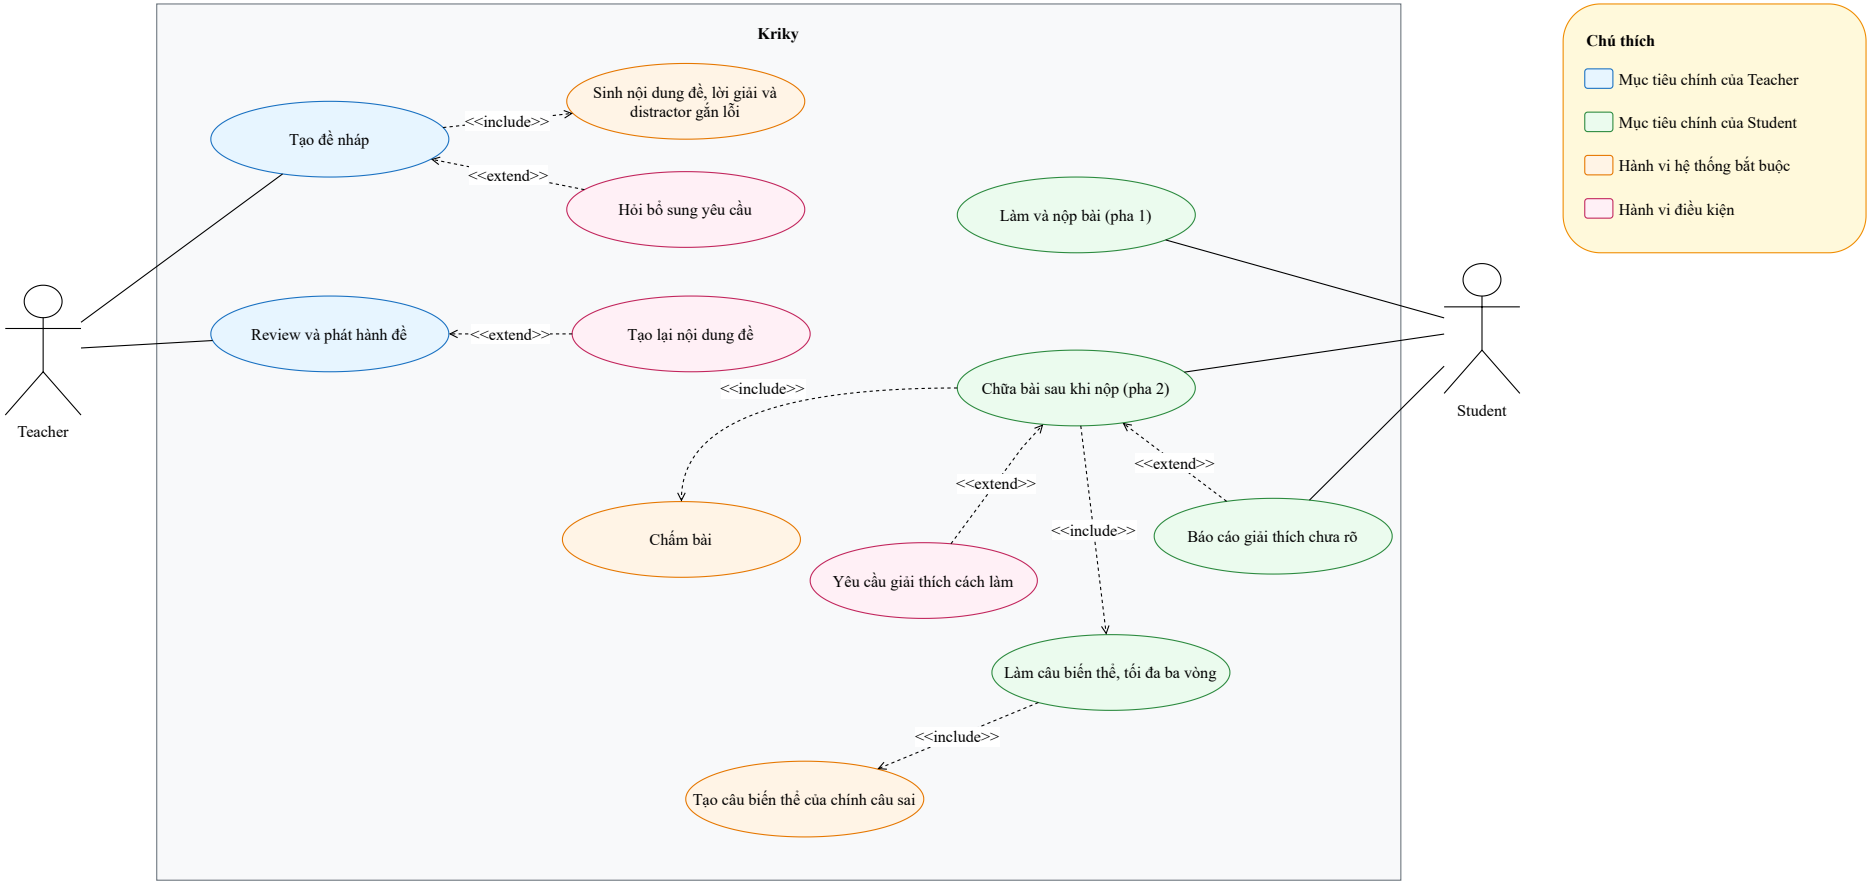
5.1 Sáu use case

Bảng 5.1: Sáu use case và actor chính của từng cái

Mã	Actor chính	Tên
UC-01	Teacher	Tạo đề nháp
UC-02	Teacher	Review và phát hành đề
UC-03	Student	Làm và nộp bài (giai đoạn 1)
UC-04	Student	Chữa bài sau khi nộp (giai đoạn 2)
UC-05	—	Hệ thống tạo câu biến thể
UC-06	Student	Báo cáo chỗ trợ lí giải thích chưa rõ

UC-05 không có **actor** (tác nhân) trực tiếp: đó là hành vi hệ thống, được `<<include>>` từ UC-04.

Hình 5.1 vẽ các use case cùng các quan hệ `<<include>>` và `<<extend>>` giữa chúng.



Hình 5.1: Use Case Diagram

5.2 Đặc tả từng use case

5.2.1 UC-01 — Tạo đề nháp

Điều kiện trước. **Teacher** (giáo viên) biết chủ đề hoặc mục tiêu học tập cần kiểm tra, và mô tả được yêu cầu ở mức đủ hiểu.

Luồng chính. Teacher nhập yêu cầu và các ràng buộc (chủ đề, số câu, độ khó, thời gian làm bài, loại bài). Hệ thống phân tích, sinh đề nháp gồm câu hỏi, các phương án, đáp án đúng, và lời giải rồi hiển thị cho Teacher.

Quan hệ. *Tạo đề nháp* `<<include>>` *Sinh nội dung đề*. *Hỏi bổ sung yêu cầu* `<<extend>>` *Tạo đề nháp*, khi yêu cầu ban đầu chưa đủ rõ — đây chính là một trong hai nơi Giáo viên ra quyết định ở mục 2.6.

5.2.2 UC-02 — Review và phát hành đề

Điều kiện trước. Đã có đề nháp.

Luồng chính. Teacher xem từng câu hỏi, xem đáp án đúng, lời giải và phương án sai; chỉnh sửa nếu cần; duyệt đề; rồi phát hành với sáu tham số. Mỗi lần phát hành cho một lớp sinh ra một **Publication** (bản ghi phát hành).

Quan hệ. *Tạo lại nội dung đề* `<<extend>>` *Review và phát hành đề*, khi Teacher thấy một phần hoặc toàn bộ đề chưa phù hợp.

5.2.3 UC-03 — Làm và nộp bài

Điều kiện trước. Bài đã được phát hành và **Student** (học sinh) có quyền truy cập.

Luồng chính. Student mở bài, đọc câu hỏi, chọn đáp án, nộp bài. Hệ thống ghi nhận, và chấm bài.

Sơ đồ *không* dùng `<<include>>` từ *Làm và nộp bài* sang *Chấm bài*: chấm bài là bước xử lý *sau* khi có bài nộp, không phải hành vi bắt buộc để Student hoàn thành mục tiêu nộp bài của mình.

Kết quả. Bài nộp được ghi nhận và được chấm. **Nộp bài không kết thúc bài kiểm tra** — nó kết thúc giai đoạn 1.

5.2.4 UC-04 — Chữa bài

Điều kiện trước. Student đã nộp bài ở giai đoạn 1 và hệ thống đã chấm; chưa quá hạn kết thúc giai đoạn 2.

Luồng chính. Student mở kết quả; mở màn hỏi trợ lí, nơi mọi câu sai nằm cùng một màn và phần giải thích không tính giờ; bấm nút làm bài mới để khởi động đồng hồ của lượt; làm câu biến thể của từng câu sai. Câu đúng thì chốt 0,5; câu còn sai thì sang vòng tiếp, tối đa ba vòng, hết ba vòng thì chốt 0.

Ngoại lệ. Hết hạn giai đoạn 2 giữa một lượt thì lượt bị *dừng* và các câu còn dở nhận 0 điểm. Student không mở giai đoạn 2 lần nào thì mọi câu sai nhận 0 điểm.

Quan hệ. *Chữa bài* `<<include>>` *Chấm bài và tra cứu lỗi sai*, và `<<include>>` *Làm câu biến thể, tối đa ba vòng*. *Yêu cầu giải thích cách làm* và *Báo cáo giải thích chưa rõ* đều `<<extend>>` từ nó.

Quan hệ với *Làm câu biến thể* là `<<include>>` chứ không phải `<<extend>>`, **vì giai đoạn 2 bắt buộc**: nó không phải một nhánh có thể không xảy ra. Đây là ví dụ rõ nhất trong cả sơ đồ về việc một quyết định sư phạm đổi luôn kiểu quan hệ trên hình.

5.2.5 UC-05 — Tạo câu biến thể

Điều kiện trước. Một câu ở giai đoạn 1 bị làm sai.

Luồng chính. Hệ thống lấy câu Student làm sai, sinh biến thể của *chính câu đó* — giữ nguyên cấu trúc và lỗi cần kiểm, thay dữ kiện — rồi đưa thẳng tới Student. Kết quả của câu biến thể quyết định câu gốc chốt 0,5 hay sang vòng tiếp.

5.2.6 UC-06 — Báo cáo Trợ lí giải thích chưa rõ

Điều kiện trước. Student đang ở giai đoạn 2, và trợ lí đã trả lời ít nhất một lần.

Luồng chính. Student bấm nút báo cáo “Trợ lí giải thích chưa rõ”. Hệ thống ghi lại **cả đoạn hội thoại của bài kiểm tra đó** kèm những câu Student làm sai để giáo viên có thể xem được.

Chương 6

Kiến trúc và mô hình dữ liệu

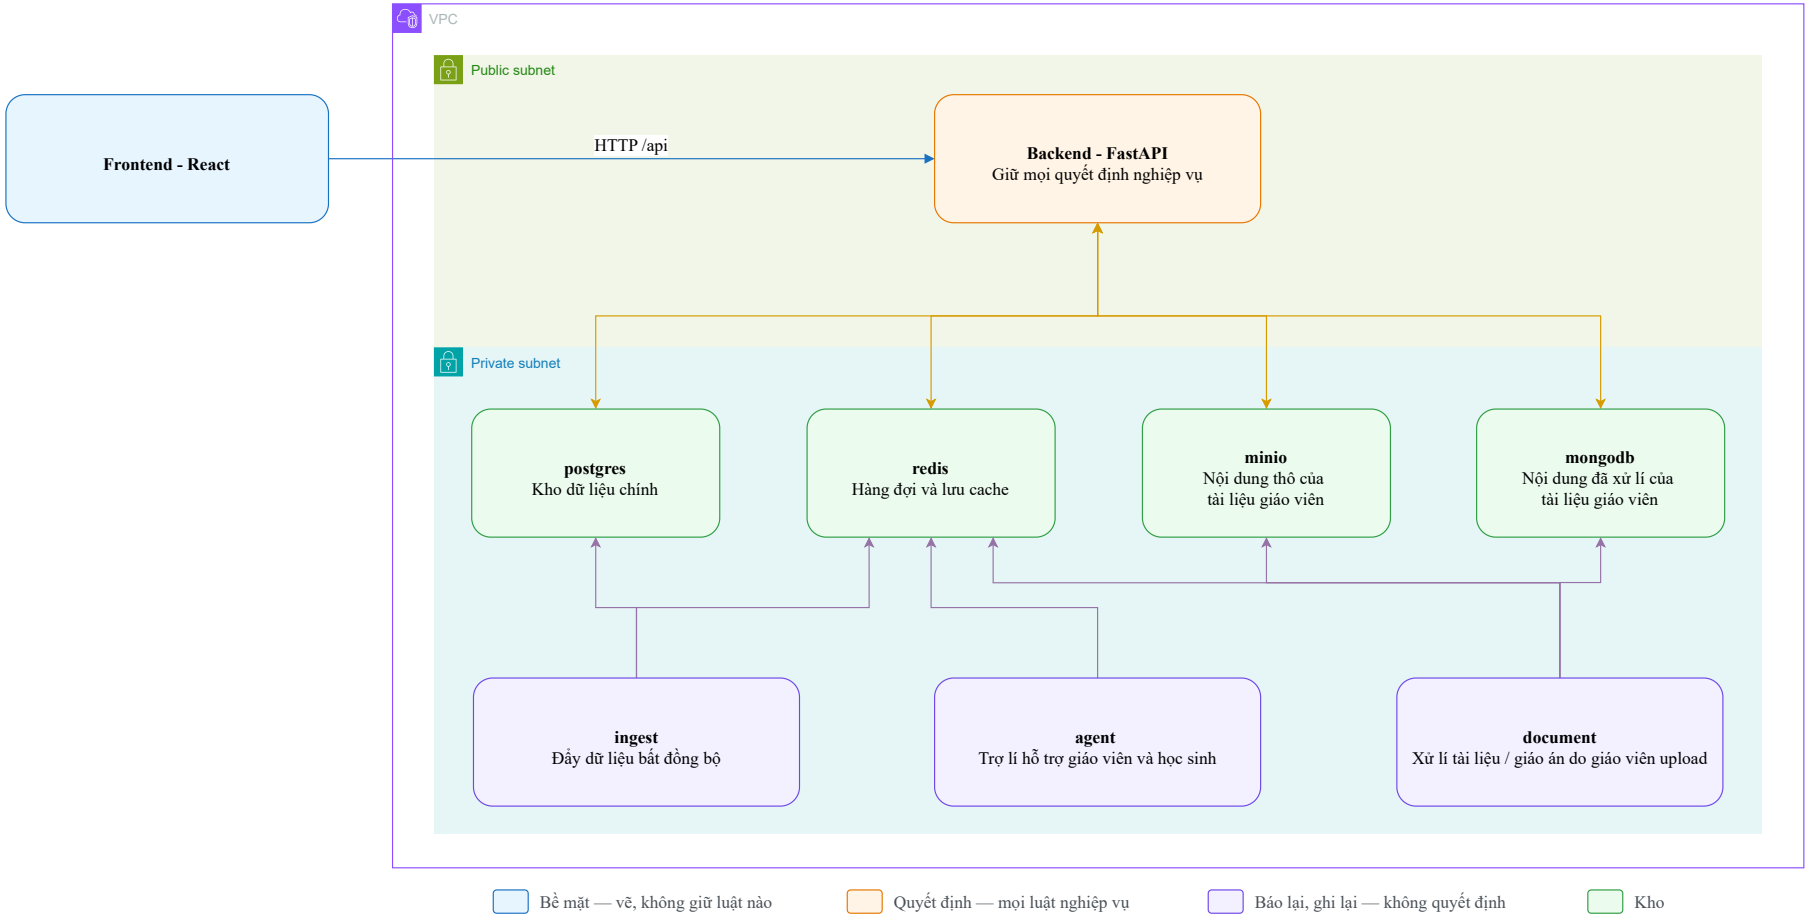
6.1 Các service trong hệ thống

Hệ thống gồm năm **service** (thành phần) chạy độc lập với nhau. Các thuật ngữ tiếng Anh của chương này được định nghĩa ở mục 3.2.

Bảng 6.1: Năm service của hệ thống

Service	Vai trò	Quyết định nghiệp vụ	Credentials
`frontend`	`frontend` cho giáo viên và học sinh. Chỉ nói chuyện với `backend`	Không	Không có
`backend`	Nơi giữ mọi quyết định nghiệp vụ, và là gateway của hệ thống	**Mọi quyết định**	postgres / redis / minio / mongodb
`agent`	Kết nối với Model Provider. Soạn câu hỏi, đề xuất bước tiếp theo cho yêu cầu của giáo viên, và giải đáp học sinh trong hội thoại	Không	redis
`document`	Kết nối với Model Provider. Đọc tài liệu giáo viên tải lên, và dựng cây mục lục cho `agent` dùng khi ra đề	Không	redis / minio / mongodb
`ingest`	Ghi vào database trạng thái xử lí mà `document` báo về	Không	redis / postgres

`frontend` không biết `agent` tồn tại. Mọi thứ nó cần đều đi qua `backend`, nên hệ thống chỉ có một **gateway** (cửa vào duy nhất).



Hình 6.1: System Architecture

6.2 Frontend không nhìn thấy bên trong hệ thống

Hình 6.1 chia hệ thống làm hai vùng, và đặt `frontend` ở ngoài cả hai. Trong **VPC** (đám mây riêng ảo), `backend` nằm ở **public subnet** (vùng mạng công khai); `agent`, `document`, `ingest` và bốn **store** (bốn kho) nằm ở **private subnet** (vùng mạng nội bộ) — chỉ những gì ở public subnet mới nhận được kết nối từ bên ngoài.

`frontend` không bao giờ biết bên trong có mấy service, hay chúng tên gì.

6.3 Backend quyết định mọi thứ

Đây là ràng buộc quan trọng nhất của kiến trúc, và nó là một ràng buộc *nghiệp vụ* chứ không phải một lựa chọn kỹ thuật. Luật chỉ có một câu: **`agent` nộp nội dung / đề xuất hành động, `backend` quyết định làm gì.**

`agent` trả về `backend` hai thứ:

- **Nội dung** — câu hỏi và lời giải cho đề kiểm tra; câu trả lời trong hội thoại với giáo viên hay học sinh; một bản phân tích đọc từ dữ liệu mà `backend` cấp cho nó.
- **Đề xuất hành động** — **tool** (công cụ) nào nên chạy, với tham số nào.

Hai thứ trên có hiệu lực hay không đều do `backend` quyết định. Với nội dung: kiểm trước khi ghi. Với hành động: chỉ chạy những tool chính nó cấp cho mô hình, và từ chối một đề xuất gọi tool ngoài danh sách ấy hay thiếu tham số.

Ví dụ, đối với việc soạn đề:

- `agent` trả về một **đề xuất**: câu hỏi, lời giải, và các phương án lựa chọn, trong đó mỗi phương án nhiễu đi kèm một lỗi cụ thể.
- `backend` kiểm tra lại ràng buộc từng câu rồi mới lưu. Và một đề chỉ rời trạng thái **draft** (nháp) khi giáo viên bấm **approve** (duyệt).

6.4 Service nào kết nối tới store nào?

Bốn store ấy là bốn loại khác nhau: postgres là một **database** (cơ sở dữ liệu) giữ dữ liệu có cấu trúc, redis là một **queue** (hàng đợi), minio là một **object store** (kho tệp) giữ **byte** (dữ liệu gốc) của tệp, và mongodb là một **content store** (kho nội dung) giữ nội dung đã xử lí. Bảng 6.2 cho biết service nào đọc, service nào ghi từng store.

Bảng 6.2: Service nào đọc, service nào ghi từng store

Store	`backend`	`agent`	`document`	`ingest`
postgres (database)	đọc, ghi	—	—	đọc, ghi
minio (object store)	ghi	—	đọc	—
mongodb (content store)	đọc	—	đọc, ghi	—
redis (queue)	đọc, ghi	đọc, ghi	đọc, ghi	đọc, ghi

Content store giữ thứ đọc được từ tài liệu. Sau khi đọc một tệp, `document` ghi vào nội dung của từng trang và cây mục lục dựng từ chúng. `backend` chỉ đọc ra, để đưa mục lục hay nội dung của một bài cho `agent` khi ra đề theo tài liệu. Tài liệu đã xử lí xong hay chưa thì vẫn do database trả lời: content store giữ *thứ đọc được từ tệp*, không giữ *sự thật về tệp*.

`agent` và `document` không có **credential** (khoá truy cập) của database.

6.5 Các service nói chuyện với nhau thế nào

Hệ thống sử dụng ba hình thức giao tiếp: gọi API trực tiếp, gửi công việc qua hàng đợi và thông báo thay đổi qua Redis Pub/Sub.

Giao tiếp trực tiếp qua API `frontend` gọi `backend`. Đó là đường duy nhất đi vào hệ thống từ bên ngoài, và cũng là lời gọi **API** (giao diện lập trình) duy nhất giữa hai service.

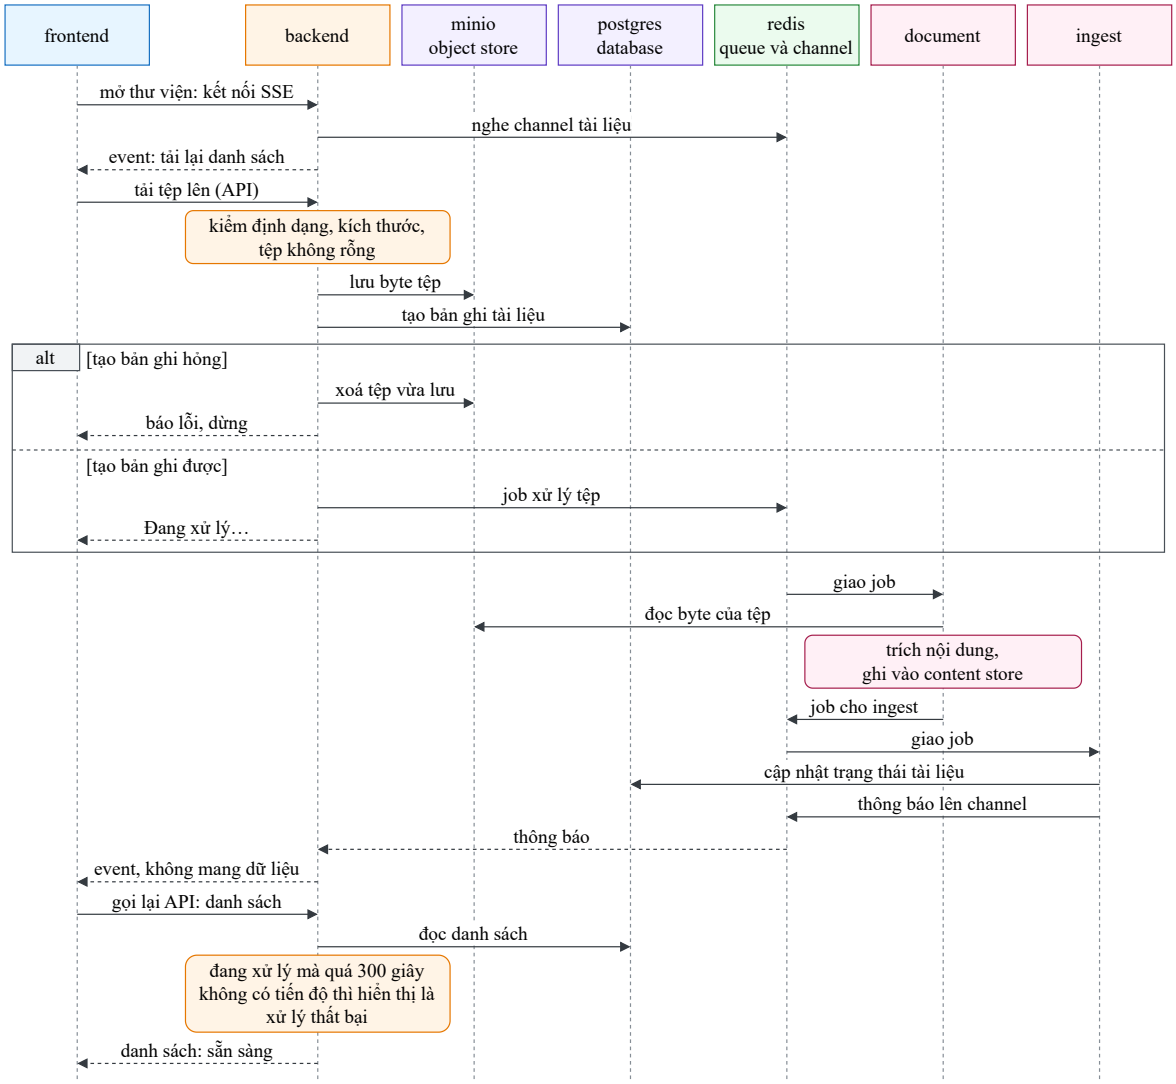
Xử lý công việc qua hàng đợi. Bên gửi đặt một **job** (một đầu việc, một lần chạy) lên queue ở `redis`, kèm **task** là tên của loại việc ấy. Một **worker** (tiến trình nền) ngồi nghe queue đó, lấy job xuống và làm. Bên gửi không bao giờ nói chuyện thẳng với worker; kết quả, nếu cần, cũng đi về qua `redis`.

Thông báo thay đổi qua Pub/Sub. Redis Pub/Sub được sử dụng để thông báo cho các thành phần khác khi có dữ liệu mới hoặc trạng thái thay đổi. Khác với hàng đợi job, thông báo Pub/Sub không được lưu lại để xử lý sau mà chỉ được gửi đến những thành phần đang đăng ký theo dõi channel tại thời điểm phát thông báo.

Hình 6.2 minh họa cả ba hình thức khi giáo viên tải lên một tài liệu.

6.6 Job nào đi qua queue, job nào không

Mọi job cần gọi **Model Provider** (nhà cung cấp mô hình) đều chạy qua một queue, đường duy nhất tới `agent` và `document`. Có sáu task như vậy: năm của `agent`, một của `document`.



Hình 6.2: Tải lên một tài liệu: gọi API, giao job qua queue, thông báo qua channel

Bảng 6.3: Sáu task gọi Model Provider

Task	Service	Khi nào xảy ra
Viết một câu hỏi	`agent`	Mỗi câu của bộ đề giáo viên yêu cầu. **Một câu một job**.
Sinh câu biến thể	`agent`	Khi học sinh nộp bài giai đoạn 1
Trả lời một tin nhắn của học sinh	`agent`	Khi học sinh cần giải đáp thắc mắc ở giai đoạn 2
Đề xuất bước tiếp theo	`agent`	Khi giáo viên gửi một tin nhắn / yêu cầu / thắc mắc; và một lần nữa sau khi `backend` chạy xong các việc của một plan, để kể lại kết quả
Đặt tên một đoạn hội thoại	`agent`	Khi giáo viên gửi tin nhắn đầu tiên và Kriky trả lời
Dựng cây mục lục	`document`	Khi tải lên tài liệu và đã đọc xong nội dung của mọi trang

Chấm bài không đi qua queue. Với trắc nghiệm, chấm là một phép so giữa phương án đã chọn và đáp án đúng đã lưu sẵn, nên nó chạy ngay trong lúc học sinh nộp bài. Kết quả nhìn thấy được trên màn hình: giữa lúc nộp và lúc xem kết quả **không có trạng thái đang chấm nào**.

Màn hình nhận event qua SSE, thay vì phải polling. **SSE** là một kết nối `backend` giữ mở để gửi event xuống khi có gì đổi; **polling** (màn hình tự hỏi lại theo chu kì) là phương án hệ thống không dùng. Có những chỗ dữ liệu hiện ra dần:

- **Hội thoại của học sinh** Hiển thị nội dung phản hồi của trợ lí theo thời gian thực.
- **Hội thoại của giáo viên** Hiển thị nội dung phản hồi của trợ lí, kế hoạch thực hiện (plan) và tiến độ của từng công việc trong kế hoạch theo thời gian thực.
- **Thư viện tài liệu của giáo viên** hiển thị "Đang xử lý…" ngay khi tệp vừa tải lên, rồi tự chuyển sang sẵn sàng mà không cần làm mới màn hình.

6.7 Nếu một service ngừng thì mất gì?

Một kiến trúc chia nhiều phần chỉ đáng giá nếu một phần hỏng không kéo cả hệ thống theo. Bảng 6.4 nói rõ từng trường hợp.

Bảng 6.4: Mỗi service ngừng thì mất gì, còn gì

Ngừng	Mất	Còn
`redis`	Mọi job cần gọi mô hình và tải lên tài liệu	Phát hành đề, làm bài, nộp bài, xem score giai đoạn 1
`minio`	`backend` không khởi động	—
`postgres`	`backend` không khởi động	—
`agent`	Soạn đề, hội thoại	Mọi thứ còn lại
`mongodb`	Ra đề theo tài liệu, và tài liệu mới không xử lí xong	`backend` vẫn khởi động; ra đề không có tài liệu và mọi thứ còn lại
`document`	Tài liệu mới không xử lí xong	Thư viện vẫn mở, tài liệu cũ vẫn dùng được để ra đề
`ingest`	Tài liệu mới không xử lí xong	Job **không mất**: nó nằm lại trên queue, bật lại thì chạy tiếp

6.8 Mô hình dữ liệu

Mô hình dữ liệu có hai mươi hai bảng, chia theo năm nhóm. Mỗi bảng trả lời đúng một câu hỏi nghiệp vụ, và phần ghi chú dưới đây nói vì sao ranh giới giữa chúng nằm ở chỗ đó.

Bảng 6.5: Hai mươi hai bảng, theo năm nhóm

Bảng	Giữ gì
Nhóm 1 — người và lớp	
`classes`	Một lớp giáo viên tạo. Lớp thuộc về giáo viên, không thuộc về nhà trường. Tên lớp *không* phải định danh
`students`	Họ tên, mã học sinh, thuộc lớp nào. Mã học sinh là khoá con người dùng
`teachers`	Họ tên và mã giáo viên
Nhóm 2 — nội dung đề	
`assessments`	Tác giả, tiêu đề, môn, khối, và *trạng thái* — bốn giá trị của vòng đời một đề: rỗng, có câu hỏi, đã duyệt, đã phát hành
`questions`	Đề bài, thứ tự câu học sinh nhìn thấy, mục tiêu học tập
`options`	Nhãn, nội dung, dấu đáp án đúng, và *lỗi mà phương án này đại diện*. Ô lỗi để trống ở đúng một dòng mỗi câu, và dòng đó chính là đáp án đúng
`methods`	Các cách giải của một câu. Bắt buộc nhiều hơn một

tiếp trang sau

Bảng	Giữ gì
`bank_questions`	Ngân hàng câu hỏi của từng giáo viên: bản chép của mỗi câu, kèm phương án và lời giải, lúc đề chứa nó được duyệt. Xoá câu khỏi đề thì bản này ở lại
`publications`	Sáu tham số phát hành, một dòng cho mỗi cặp đề và lớp, nên thu hồi được từng lớp một
`documents`	Tài liệu giáo viên tải lên: tên tệp, kích thước, khoá trỏ tới object store, trạng thái xử lý, số trang, số trang đã đọc, lý do hỏng. **Không giữ byte nào**. Thuộc về giáo viên, không thuộc về đề
`draft_briefs`	Yêu cầu soạn của một đề: môn, khối, phạm vi, tổng số câu đã xin; tài liệu và các nút của cây mục lục khi ra đề theo tài liệu; và các mục dàn ý giáo viên đã đồng ý
`draft_items`	Một ô cho mỗi câu đang soạn, kèm mục dàn ý câu ấy theo, trạng thái, số lần đã thử, và *lý do* lần gần nhất bị loại
Nhóm 3 — bài làm và điểm	
`attempts`	Một học sinh làm một đề: lớp lúc bắt đầu, giờ bắt đầu, giờ phải xong, giờ đã nộp
`answers`	Lựa chọn ở giai đoạn 1, ghi mỗi lần bấm chứ không gom tới lúc nộp
`question_outcomes`	**Sổ điểm**: mark cuối, lý do, số vòng đã dùng, đã chốt hay chưa
Nhóm 4 — giai đoạn 2	
`rounds`	Một lượt làm lại và giờ kết thúc của nó, đã cắt xuống hạn giai đoạn 2 nếu vượt
`round_items`	Câu sinh cho lượt đó, kèm phương án và lời giải — giữ cả đáp án đúng ở đây là thứ cho phép hệ thống tự chấm lượt
`pregenerated_items`	Câu viết *trước* khi học sinh bấm nút, trong lúc em còn đang đọc giải thích
`chat_messages`	Từng tin nhắn giữa học sinh và trợ lí. Câu trả lời hiện dần lên màn hình và chỉ được lưu khi đã trọn vẹn; đóng thẻ trình duyệt giữa chừng thì câu ấy mất, và trợ lí chỉ trả lời lại khi em gửi tin nhắn tiếp theo
`reports`	Báo cáo *giải thích chưa rõ*, gắn với cả bài chứ không với một tin nhắn
Nhóm 5 — hội thoại của giáo viên	

tiếp trang sau

Bảng	Giữ gì
`teacher_conversations`	Một đoạn hội thoại của một giáo viên. Tiêu đề do trợ lí đặt sau lượt hội thoại đầu tiên, giáo viên sửa được; xoá là *xoá mềm*
`teacher_turns`	Từng *bước* của một lượt hội thoại: lời nói, plan, dàn ý, hoặc tool đã chạy, kèm chủ thể mà bước đó nói về

Thứ đọc được từ tài liệu không nằm trong hai mươi hai bảng này mà ở content store; database chỉ biết một tài liệu đã xử lí xong hay chưa.

Chương 7

Chi tiết các service

Chương 6 đã trình bày kiến trúc tổng thể của hệ thống, bao gồm vai trò của các service, phạm vi dữ liệu mà mỗi service quản lý và cơ chế giao tiếp giữa chúng. Trên cơ sở đó, chương này đi sâu vào thiết kế và triển khai ba service đảm nhiệm các chức năng xử lý chính: `backend`, `agent` và `document`.

Đối với mỗi service, nội dung tập trung vào vai trò và trách nhiệm, cách tổ chức và xử lý các tác vụ, những cơ chế kỹ thuật quan trọng, cùng các ràng buộc và phương án xử lý lỗi. Tùy theo đặc điểm của từng service, các nội dung được tổ chức để làm rõ những quyết định thiết kế và cách chúng được hiện thực trong hệ thống.

7.1 Backend

7.1.1 Vai trò và trách nhiệm

`backend` là **gateway** (cửa vào duy nhất) của hệ thống: mọi yêu cầu từ màn hình của giáo viên hay học sinh đều tới nó qua một lời gọi **API** (giao diện lập trình). Với mỗi lời gọi, `backend` xác định người gọi là ai, kiểm dữ liệu được hỏi có thuộc về người ấy không và trạng thái hiện tại có cho phép thao tác ấy không, rồi mới đọc hay ghi **database** (cơ sở dữ liệu). Mọi dữ liệu nghiệp vụ trong database đều do `backend` ghi, trừ kết quả và tiến độ xử lý tài liệu, do `ingest` ghi.

Với các yêu cầu thông thường, `backend` trả kết quả ngay sau khi đọc hoặc cập nhật dữ liệu. Riêng những chức năng cần cập nhật thông tin liên tục, hệ thống sử dụng **SSE** (Server-Sent Events) để gửi sự kiện từ `backend` đến `frontend`. Cơ chế này được sử dụng trong ba chức năng: hội thoại giáo viên, hội thoại học sinh và thư viện tài liệu. Nhờ đó, giao diện có thể hiển thị nội dung phản hồi hoặc nhận thông báo về những thay đổi ngay trong quá trình xử lý, thay vì phải chờ đến khi toàn bộ công việc hoàn tất.

Đối với các tác vụ mất nhiều thời gian, chẳng hạn như tạo nội dung bằng mô hình ngôn ngữ hoặc xử lý tài liệu, `backend` không trực tiếp thực hiện mà chuyển chúng cho các service chuyên trách. Mỗi tác vụ được gửi dưới dạng một **job** (đơn vị công việc) vào hàng đợi của `redis`, kèm theo **task** để xác định loại công việc cần thực hiện. Các worker của `agent` hoặc `document` nhận job từ hàng đợi, thực hiện và trả kết quả thông qua `redis`.

Trong đó, `agent` không có quyền ghi trực tiếp vào database. Các kết quả do `agent` tạo ra phải được chuyển về `backend` để kiểm tra trước khi lưu. Tuy nhiên, `backend` không có worker

riêng để liên tục thu nhận kết quả các job đã giao. Vì vậy, tùy theo yêu cầu của từng chức năng, nó sử dụng các cơ chế nhận kết quả khác nhau, được trình bày trong mục tiếp theo.

7.1.2 Giao job, lấy kết quả và gửi event

Ba cách nhận kết quả. Các tác vụ do `agent` thực hiện có thời gian xử lý và yêu cầu phản hồi khác nhau. Với những tác vụ cần kết quả ngay, `backend` giữ kết nối với `frontend` trong khi chờ job hoàn tất. Ngược lại, những tác vụ có thể chạy nền được giao đi mà không cần chờ kết quả. Bảng 7.1 tổng hợp ba cách `backend` nhận kết quả từ `agent`.

Bảng 7.1: Ba cách nhận kết quả từ `agent`

Cách nhận kết quả	Trường hợp sử dụng
Chờ job hoàn tất	Các bước xử lý trong hội thoại giáo viên; tạo câu biến thể khi học sinh cần sử dụng ngay
Nhận và gửi nội dung liên tục	Trả lời tin nhắn trong hội thoại học sinh
Gửi job và nhận kết quả sau	Tạo từng câu hỏi của đề; chuẩn bị trước câu biến thể

Với cách thứ nhất, `backend` giữ yêu cầu mở và chờ `agent` hoàn thành công việc trước khi tiếp tục xử lý. Cách này được sử dụng trong hội thoại giáo viên và khi học sinh cần tạo câu biến thể ngay để bắt đầu làm bài trong giai đoạn 2.

Cách thứ hai được sử dụng trong hội thoại học sinh. Thay vì chờ câu trả lời hoàn chỉnh, `backend` nhận từng phần nội dung do `agent` tạo ra và chuyển ngay xuống giao diện qua SSE. Nhờ đó, học sinh có thể đọc câu trả lời trong khi nó vẫn đang được tạo. Thời gian chờ được tính từ lần nhận nội dung gần nhất: nếu không có nội dung mới trong 25 giây, hệ thống báo lỗi; mỗi khi nhận được nội dung mới, thời gian chờ được tính lại.

Với cách thứ ba, `backend` gửi job nhưng không chờ kết quả trong yêu cầu hiện tại. Khi có yêu cầu tiếp theo, nó kiểm tra và thu nhận kết quả của những job đã hoàn thành. Cơ chế này được sử dụng khi soạn đề, trong đó mỗi câu hỏi được tạo bằng một job độc lập. Nó cũng được dùng để chuẩn bị trước câu biến thể ngay sau khi học sinh nộp bài, giúp giảm thời gian chờ khi học sinh chuyển sang giai đoạn 2.

Riêng job xử lý tệp của `document` không sử dụng ba cách trên. Kết quả xử lý tài liệu được cập nhật vào database thông qua `ingest`, thay vì được `backend` trực tiếp thu nhận.

Thu hoạch kết quả. Đối với các job được giao mà không cần chờ, kết quả sau khi hoàn thành được lưu tạm trong `redis` trong tối đa một giờ. Do `backend` không có worker riêng để tiếp nhận các kết quả này, việc xử lý chúng được thực hiện khi có yêu cầu hoặc thông báo phù hợp. Cơ chế này được gọi là *thu hoạch kết quả*: `backend` kiểm tra những job đã hoàn thành, lấy kết quả từ `redis`, kiểm tra tính hợp lệ và lưu kết quả đạt yêu cầu vào database. Những kết quả không hợp lệ sẽ được yêu cầu tạo lại trong giới hạn số lần thử cho phép.

Việc thu hoạch được kích hoạt trong hai trường hợp. Thứ nhất, khi có yêu cầu liên quan đến một đề đang được soạn, chẳng hạn như xem chi tiết, chỉnh sửa hoặc duyệt đề, `backend` sẽ thu hoạch các câu hỏi đã hoàn thành trước khi xử lý yêu cầu. Tương tự, khi học sinh mở màn

hình chữa bài hoặc bắt đầu một lượt làm lại, hệ thống sẽ thu hoạch các câu biến thể đã được chuẩn bị trước. Thứ hai, trong quá trình hội thoại với giáo viên, nếu `agent` thông báo một câu hỏi đã được tạo xong, `backend` sẽ thu hoạch kết quả và cập nhật số câu đã hoàn thành trên giao diện qua SSE.

Một điểm đáng chú ý là quá trình thu hoạch có thể làm thay đổi database ngay cả khi yêu cầu ban đầu chỉ nhằm đọc dữ liệu. Chẳng hạn, thao tác xem chi tiết đề có thể đồng thời lưu thêm những câu hỏi vừa được tạo xong. Thiết kế này giúp dữ liệu hiển thị phản ánh các kết quả đã hoàn thành, thay vì phải chờ một tiến trình nền riêng cập nhật. Đồng thời, việc thu hoạch được thiết kế để không ghi trùng những kết quả đã xử lý, nên có thể thực hiện nhiều lần mà không tạo ra dữ liệu trùng lặp.

Thông báo và cập nhật giao diện. Bên cạnh việc nhận kết quả job, `backend` còn sử dụng Redis Pub/Sub để tiếp nhận thông báo từ các service khác. Hệ thống có ba loại channel phục vụ các mục đích khác nhau: truyền từng phần nội dung câu trả lời của trợ lí học sinh, thông báo khi một câu hỏi của đề được tạo xong, và thông báo khi trạng thái tải lên tài liệu của giáo viên thay đổi.

Do Redis Pub/Sub không lưu lại các thông báo đã gửi, `backend` cần đăng ký lắng nghe trước khi công việc bắt đầu phát thông báo. Đối với hội thoại học sinh và quá trình soạn câu hỏi, `backend` đăng ký channel trước khi giao job cho `agent`, tránh bỏ lỡ những thông báo đầu tiên. Với thư viện tài liệu, sau khi thiết lập kết nối nhận thông báo, `backend` yêu cầu `frontend` tải lại danh sách tài liệu. Cách này giúp giao diện nhận được trạng thái mới nhất, kể cả khi có thay đổi xảy ra trước lúc kết nối được thiết lập.

Các sự kiện được `backend` gửi đến `frontend` qua SSE có nội dung khác nhau tùy theo chức năng. Trong hội thoại giáo viên, mỗi event chứa thông tin cần thiết để cập nhật giao diện và chỉ được gửi sau khi dữ liệu tương ứng đã được lưu vào database. Nhờ đó, nội dung đã hiển thị có thể được khôi phục khi tải lại trang. Trong hội thoại học sinh, `frontend` nhận từng phần câu trả lời khi chúng được tạo ra, tiếp theo là event thông báo hoàn tất hoặc báo lỗi. Đối với thư viện tài liệu, event chỉ đóng vai trò thông báo có thay đổi, còn `frontend` sẽ gọi lại API để lấy danh sách tài liệu mới nhất.

Tương tự, số câu hỏi đã hoàn thành trong quá trình soạn đề luôn được xác định từ database, thay vì cộng dồn theo số thông báo nhận được. Điều này giúp tránh sai lệch khi một thông báo bị bỏ lỡ hoặc khi một câu hỏi phải tạo lại và phát sinh nhiều thông báo.

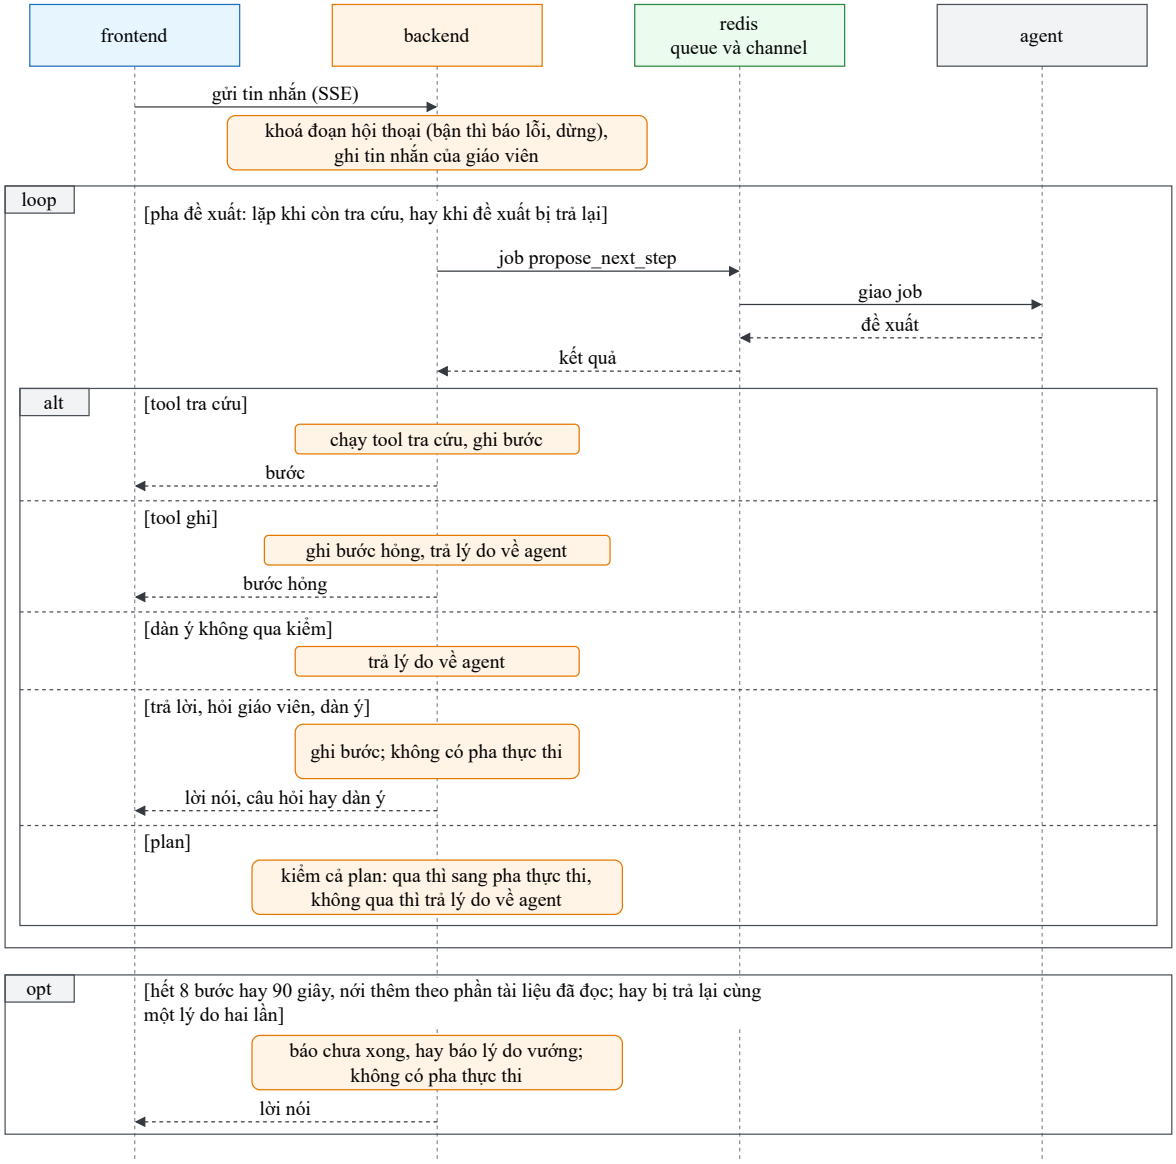
7.1.3 Xử lý các nghiệp vụ chính

Phần này trình bày cách `backend` điều phối và kiểm soát các nghiệp vụ chính của hệ thống. Các luồng nghiệp vụ đã được giới thiệu trong chương 4; nội dung dưới đây tập trung vào các bước xử lý, điều kiện kiểm tra và quyết định do `backend` đảm nhiệm.

Điều phối lượt hội thoại của giáo viên. Hình 7.6 ở cuối mục minh họa quá trình xử lý một lượt hội thoại giữa giáo viên và trợ lí. Trước khi bắt đầu, `backend` khóa đoạn hội thoại bằng một thao tác ghi có điều kiện trên database, nhằm ngăn nhiều yêu cầu cùng xử lý một đoạn hội thoại. Nếu giáo viên gửi tin nhắn đồng thời từ hai thẻ trình duyệt, chỉ một yêu cầu được tiếp nhận; yêu cầu còn lại nhận event thông báo hội thoại đang bận. Sau đó, quá trình xử lý được chia thành hai pha: đề xuất và thực thi.

Trong pha đề xuất, `backend` gửi các job đến `agent` để xác định bước xử lý tiếp theo. `agent` có thể yêu cầu sử dụng công cụ tra cứu, chẳng hạn như xem thông tin lớp, kết quả bài kiểm tra hoặc nội dung tài liệu. `backend` thực hiện các yêu cầu tra cứu hợp lệ rồi chuyển kết quả cho `agent` ở bước tiếp theo. Quá trình này tiếp tục cho đến khi `agent` đưa ra câu trả lời, yêu cầu giáo viên cung cấp thêm thông tin, tạo dàn ý hoặc đề xuất một kế hoạch thực hiện (*plan*). Ba trường hợp đầu kết thúc lượt hội thoại, còn trường hợp cuối được chuyển sang bước kiểm tra kế hoạch.

Để tránh quá trình đề xuất kéo dài, pha này có giới hạn mặc định là tám bước và chín mươi giây. Giới hạn số bước giúp kiểm soát số lần gọi mô hình, trong khi giới hạn thời gian ngăn hệ thống tiếp tục mở bước mới khi quá trình xử lý đã kéo dài quá lâu. Với mỗi phần tài liệu được đọc thêm, hệ thống cho phép tăng một bước và mười giây, tối đa mười phần tài liệu. Hình 7.1 vẽ pha đề xuất cùng hai giới hạn ấy.



Hình 7.1: Pha đề xuất của một lượt hội thoại của giáo viên

Trong pha đề xuất, `agent` chỉ được yêu cầu thực hiện các công cụ tra cứu. Những công cụ có khả năng thay đổi dữ liệu chỉ được phép xuất hiện trong kế hoạch, không được thực thi trực

tiếp ở pha này. Nếu agent yêu cầu sử dụng một công cụ ghi dữ liệu, backend từ chối và yêu cầu đưa thao tác đó vào kế hoạch. Đối với dàn ý do agent tạo ra, backend cũng kiểm tra, xây dựng nội dung hiển thị từ các mục của dàn ý và lưu lại trước khi gửi đến giáo viên. Nhờ đó, dàn ý giáo viên đã xem được sử dụng nhất quán trong các tác vụ soạn câu hỏi sau này.

Khi nhận được kế hoạch từ agent, backend kiểm tra toàn bộ kế hoạch trước khi cho phép thực thi. Với kế hoạch soạn câu hỏi, nội dung phải phù hợp với dàn ý đã hiển thị ở lượt hội thoại trước. Những thông tin còn thiếu, như số câu, đề kiểm tra hoặc tài liệu tham chiếu, được bổ sung từ dàn ý đã lưu. Nếu kế hoạch không phù hợp hoặc chưa có dàn ý tương ứng, backend trả lại cho agent để điều chỉnh trong pha đề xuất.

Sau đó, backend tiếp tục kiểm tra tính hợp lệ của kế hoạch: không quá tám công việc, mỗi công việc phải sử dụng một công cụ được cho phép và cung cấp đầy đủ tham số. Nếu một công việc cần kết quả từ công việc khác, nó chỉ được tham chiếu đến những công việc đứng trước. Nếu không đáp ứng các điều kiện này, toàn bộ kế hoạch bị từ chối và không có công việc nào được thực hiện. Ngoài ra, các công cụ của trợ lí không bao gồm thao tác duyệt hoặc phát hành đề, nên hai thao tác này chỉ có thể được thực hiện trực tiếp bởi giáo viên. Hình 7.2 vẽ hai lần kiểm này.

Khi kế hoạch hợp lệ, backend chuyển sang pha thực thi và lần lượt thực hiện các công việc theo thứ tự đã đề xuất, không cần hỏi lại agent. Kết quả của từng công việc được lưu vào database trước khi gửi event cập nhật giao diện qua SSE. Nếu một công việc gặp lỗi, hệ thống dừng thực hiện những công việc còn lại. Riêng đối với tác vụ soạn đề, mỗi câu hỏi được giao thành một job độc lập; backend nhận thông báo hoàn thành, thu hoạch kết quả và cập nhật tiến độ cho giáo viên.

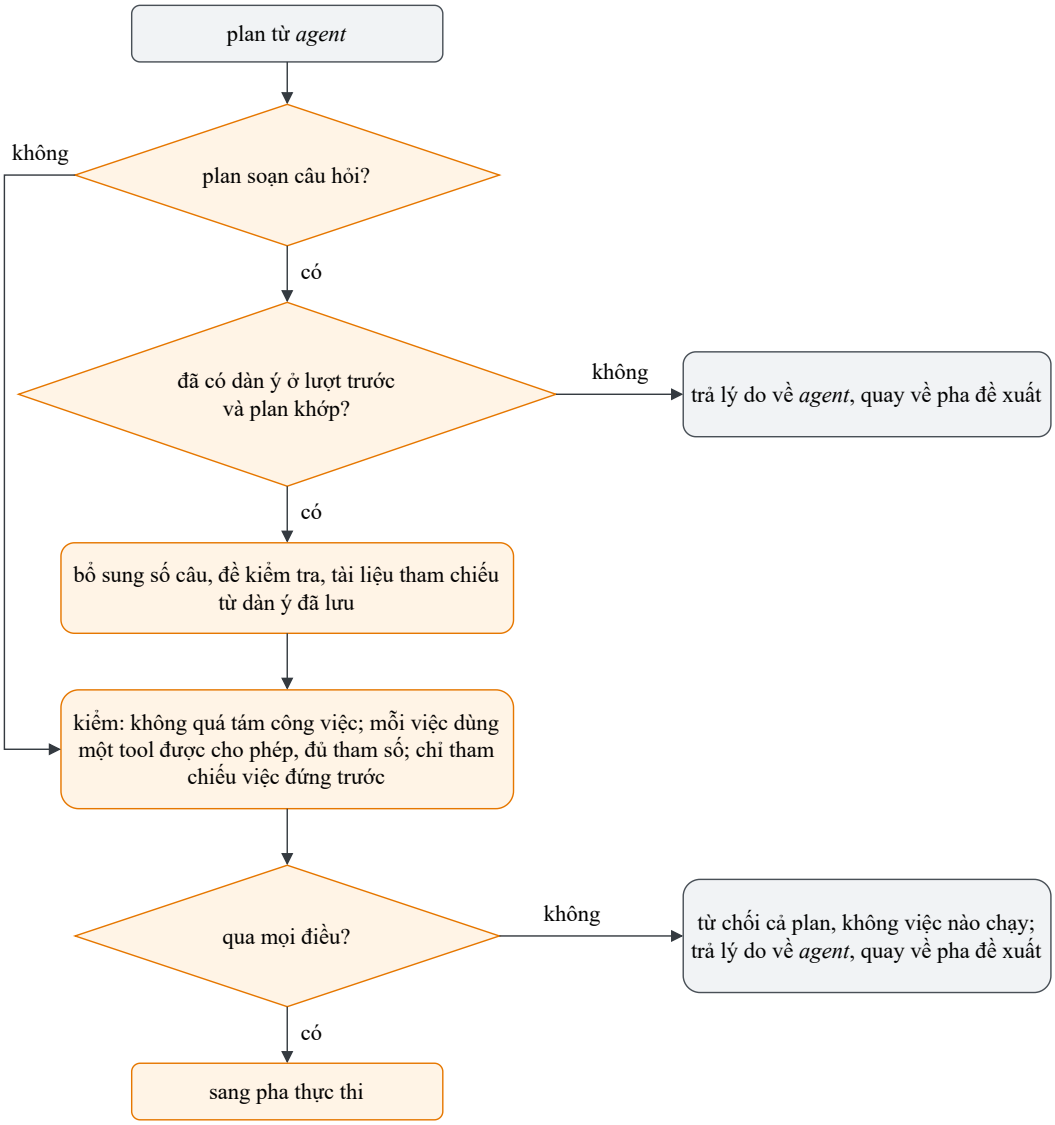
Sau pha thực thi, backend hỏi agent thêm một lượt đề xuất để kể lại kết quả các công việc thành phản hồi cuối cùng, trong đó số câu hỏi hoàn thành được xác định từ database. Nếu đây là lượt hội thoại đầu tiên, hệ thống còn tạo tên cho đoạn hội thoại bằng một job riêng. Cuối cùng, backend giải phóng khóa hội thoại, kể cả khi quá trình xử lý gặp lỗi. Hình 7.3 vẽ pha thực thi và phần kết thúc của lượt.

Soạn đề và vòng đời của đề. Quá trình soạn đề được chia thành các job độc lập, mỗi job phụ trách tạo một câu hỏi ở vị trí xác định. Chẳng hạn, yêu cầu soạn mười câu sẽ tạo ra mười job. Các job trong cùng một lần soạn sử dụng chung bản yêu cầu đã lưu, kèm theo số phiên bản để xác định tính hợp lệ của kết quả. Khi nhận được câu hỏi từ một phiên bản cũ, backend sẽ bỏ qua kết quả đó. Đồng thời, hệ thống không cho phép bắt đầu lần soạn mới khi đề vẫn còn câu hỏi đang được xử lý.

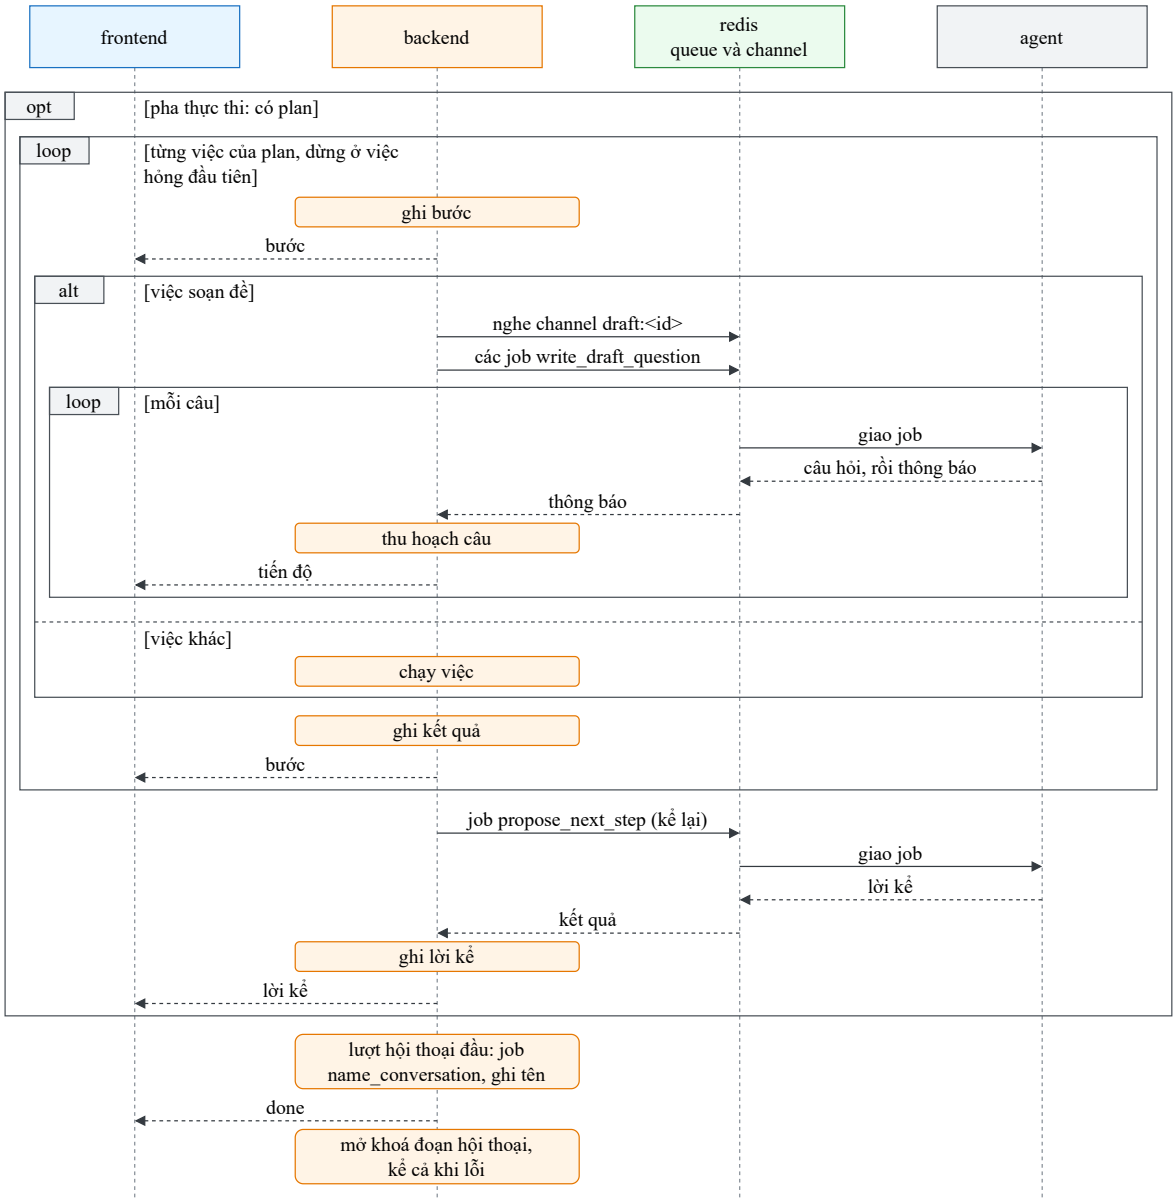
Hình 7.4 vẽ đời một câu hỏi của đề, từ lúc được giao tới khi được ghi vào đề.

Sau khi hoàn tất quá trình soạn, giáo viên có thể duyệt đề. Bảng 7.2 nói backend kiểm gì trước mỗi thao tác trên đề, và vi phạm thì ra sao.

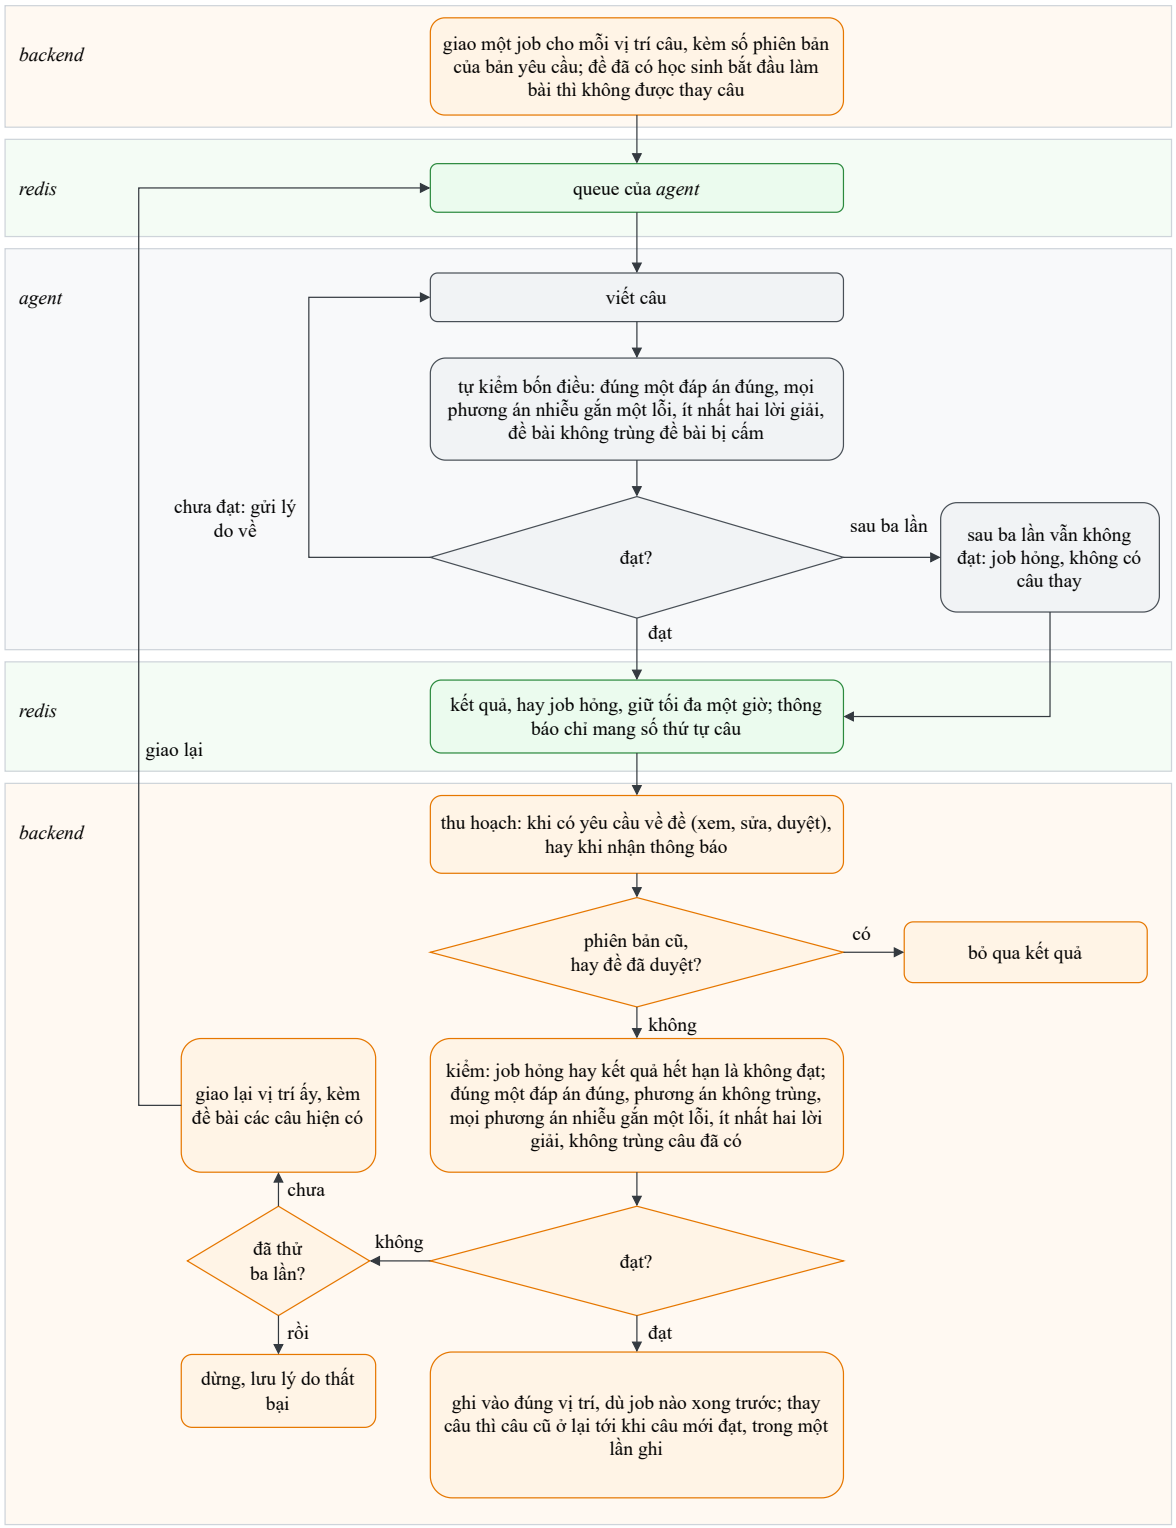
Làm bài, chấm bài và giai đoạn 2. Khi học sinh bắt đầu làm bài, backend tạo một **Attempt** (lần làm bài) và xác định thời điểm kết thúc dựa trên thời gian quy định của đề. Thời hạn này được kiểm tra tại backend, thay vì phụ thuộc vào đồng hồ đếm ngược trên giao diện. Những câu trả lời gửi đến sau thời hạn sẽ bị từ chối. Đồng thời, mỗi học sinh chỉ có một Attempt cho mỗi đề, nên các yêu cầu bắt đầu làm bài đồng thời từ nhiều thẻ trình duyệt đều nhận về cùng một Attempt.



Hình 7.2: Kiểm một plan trước khi thực thi: hỏng ở lần kiểm nào thì lý do cũng về lại `agent`



Hình 7.3: Pha thực thi và phần kết thúc của một lượt hội thoại của giáo viên



Hình 7.4: Đời một câu hỏi của đề: viết, tự kiểm ở `agent`, thu hoạch và kiểm ở `backend`

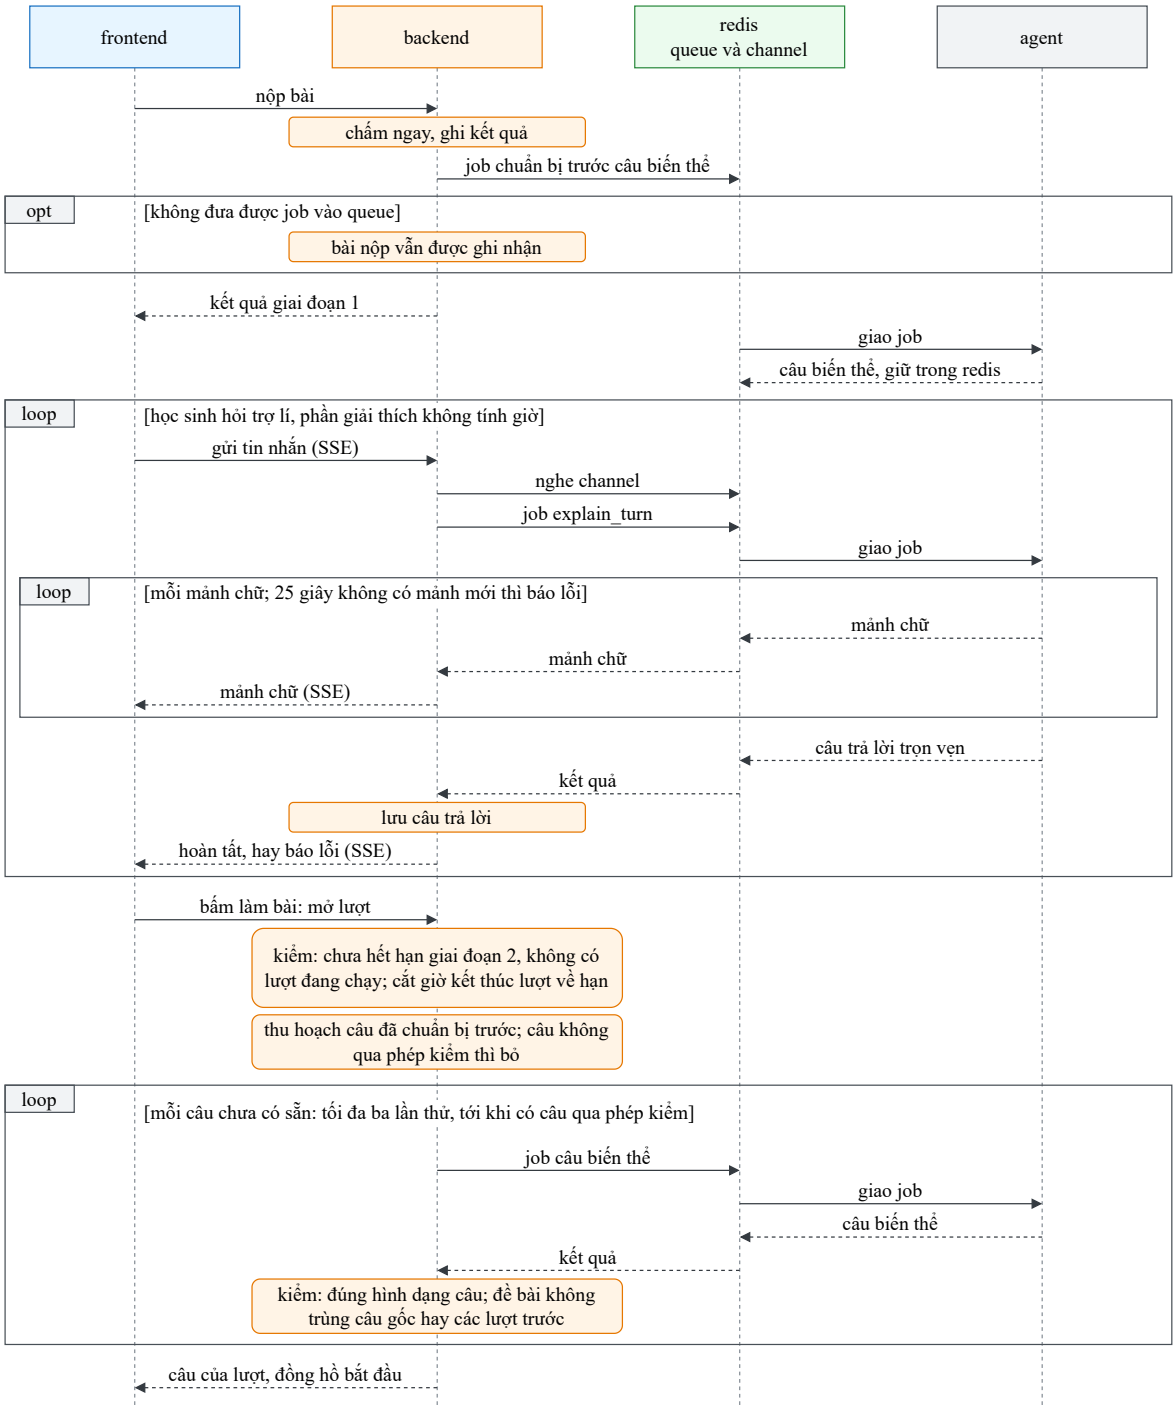
Bảng 7.2: Các thao tác trên đề: điều kiện backend kiểm, phạm vi, và kết cục khi vi phạm

Thao tác	Điều kiện backend kiểm	Phạm vi	Vi phạm thì
Duyệt đề	Thu hoạch các kết quả đã hoàn thành; đề có ít nhất một câu hỏi và không còn câu nào đang được tạo	Cả đề: chuyển sang trạng thái đã duyệt và sao chép toàn bộ câu hỏi vào ngân hàng câu hỏi trong cùng một lần ghi. Từ đó mọi thao tác thay đổi câu hỏi, kể cả ghi kết quả từ các job hoàn thành sau đó, bị từ chối cho đến khi giáo viên bỏ duyệt	Từ chối duyệt
Phát hành	Đề đã duyệt, hay đã phát hành và đang thêm lớp; điều kiện phát hành kiểm riêng cho từng lớp	Nhiều lớp, cùng một khung thời gian	Đề chưa duyệt thì cả yêu cầu bị từ chối; lớp không đạt bị từ chối, các lớp còn lại vẫn được phát hành
Phát hành lại	Lớp chưa qua giờ mở đề và chưa có học sinh bắt đầu làm bài	Từng lớp	Thao tác với lớp đó bị từ chối, không ảnh hưởng đến các lớp còn lại
Bỏ duyệt đề đã phát hành	Mọi lớp đều chưa đến giờ mở đề	Thu hồi đề khỏi tất cả các lớp, trong một lần ghi vào database	Toàn bộ thao tác bị từ chối, để tránh tình trạng đề chỉ được thu hồi ở một số lớp

Việc chấm điểm được thực hiện ngay khi backend xử lý yêu cầu nộp bài. Sau đó, hệ thống giao các job cho agent để chuẩn bị trước câu hỏi biến thể tương ứng với những câu học sinh trả lời sai. Đây là các tác vụ độc lập với việc nộp bài, nên nếu không thể đưa job vào hàng đợi, kết quả nộp bài vẫn được ghi nhận bình thường.

Hình 7.5 vẽ đường đi từ lúc nộp bài tới khi một lượt của giai đoạn 2 bắt đầu.

Quản lý tài liệu. Thư viện tài liệu cung cấp ba chức năng chính: tải tệp lên, xem danh sách tài liệu kèm trạng thái xử lý và nhận thông báo thay đổi qua SSE. Khi giáo viên tải lên một tệp, backend kiểm tra định dạng, kích thước và bảo đảm tệp không rỗng trước khi tiến hành lưu trữ. Dữ liệu gốc của tệp được lưu vào **object store** (kho tệp) trước, sau đó backend mới tạo bản ghi tài liệu trong database. Nếu không thể tạo bản ghi, hệ thống sẽ xóa tệp vừa lưu. Thứ tự này nhằm tránh trường hợp database chứa bản ghi tham chiếu đến một tệp không tồn tại. Ngược lại, nếu tệp còn sót lại trong object store mà không có bản ghi tương ứng, nó sẽ không xuất hiện trong thư viện và có thể được dọn dẹp sau. Chỉ khi bản ghi được tạo thành công, backend mới giao job cho document để bắt đầu xử lý tệp. Hình 6.2 ở mục 6.5 vẽ trọn đường đi của một tệp.



Hình 7.5: Nộp bài, hỏi trợ lí và mở một lượt của giai đoạn 2

Trạng thái tài liệu được xác định khi backend xử lý yêu cầu xem danh sách. Nếu một tài liệu vẫn ở trạng thái đang xử lý nhưng không có cập nhật tiến độ trong hơn 300 giây, hệ thống sẽ hiển thị tài liệu đó là đã xử lý thất bại. Đây chỉ là trạng thái được xác định khi đọc, không làm thay đổi trạng thái đang lưu trong database.

Ngoài việc quản lý tệp và trạng thái xử lý, backend còn truy cập nội dung đã trích xuất trong **content store** (kho nội dung) để phục vụ các nghiệp vụ khác. Cụ thể, nội dung tài liệu được sử dụng khi agent thực hiện tra cứu trong hội thoại giáo viên, khi xây dựng dàn ý và khi mở đề dựa trên tài liệu. Hệ thống không cung cấp API riêng để frontend đọc trực tiếp mục lục hoặc nội dung tài liệu. Thông tin về chương, bài được hiển thị thông qua hội thoại với trợ lí, còn nội dung văn bản của tài liệu không được gửi trực tiếp xuống giao diện. Đối với tác vụ soạn câu hỏi, backend chỉ chuyển các mục thuộc dàn ý mà giáo viên đã xem, thay vì gửi nội dung gốc của tài liệu.

7.1.4 Xử lý lỗi

Ảnh hưởng của việc một service ngừng hoạt động đã được trình bày trong bảng 6.4. Phần này tập trung vào cách backend xử lý các lỗi phát sinh trong quá trình thực hiện nghiệp vụ, bao gồm lỗi tác vụ và kết quả, sự cố kết nối SSE, quản lý khóa hội thoại và xử lý tài liệu. Các tình huống cùng phương án xử lý tương ứng được tổng hợp trong bảng 7.3.

Bảng 7.3: Các tình huống lỗi và cách xử lý của backend

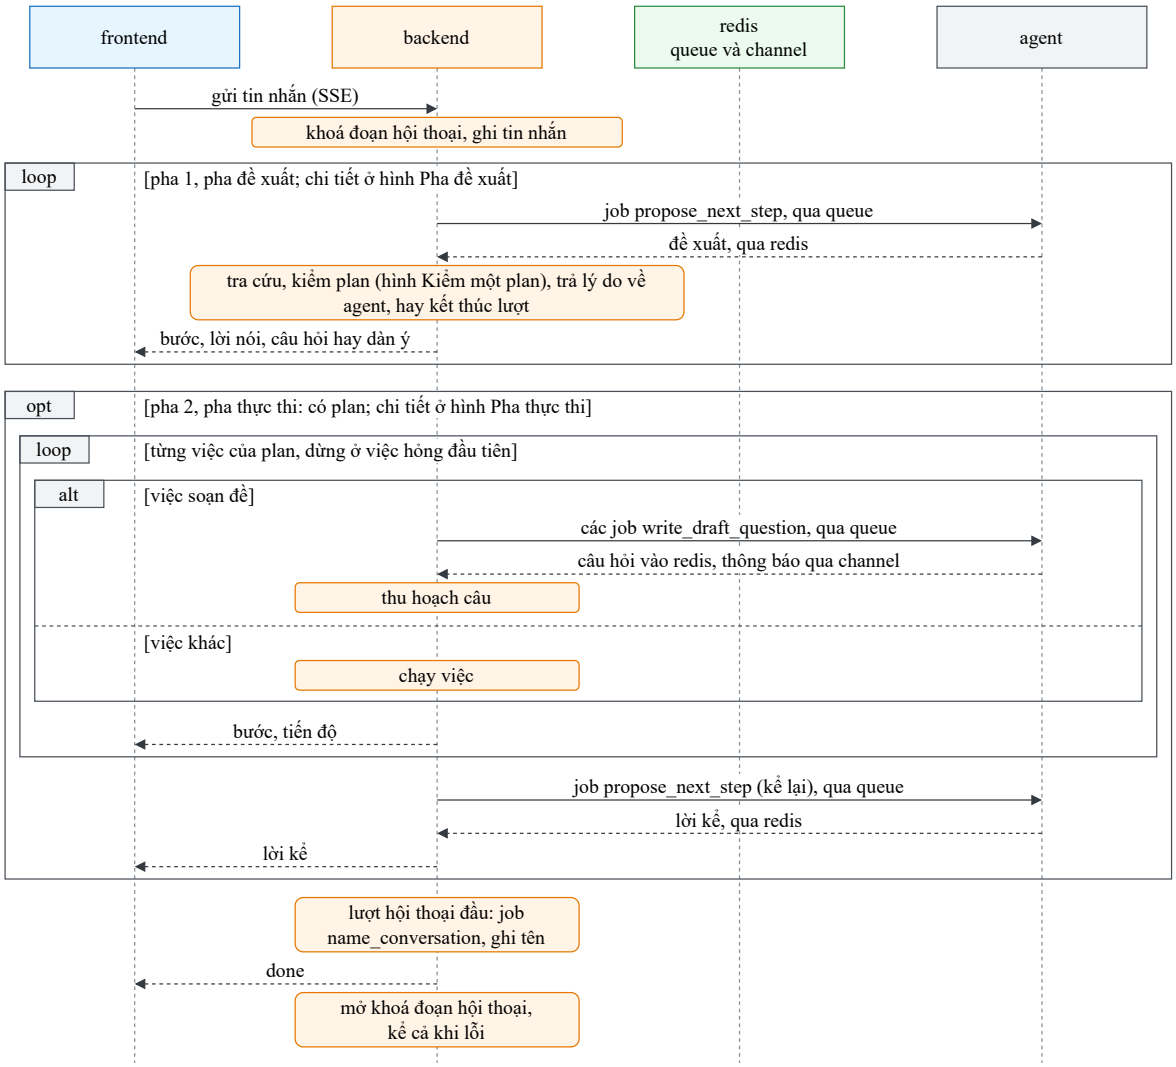
Tình huống lỗi	Cách xử lý
Job và kết quả	
Không nhận được kết quả từ job đề xuất trong hội thoại giáo viên	Kết thúc lượt hội thoại và gửi event thông báo lỗi đến giao diện.
Lượt kể lại hỏng sau khi thực hiện kế hoạch	Lưu một thông báo hệ thống thay cho câu kết; kết quả từng công việc vẫn hiện trên giao diện.
Job đặt tên hội thoại không trả kết quả	Sử dụng nội dung tin nhắn đầu tiên của giáo viên, được rút gọn, làm tên hội thoại.
Không nhận được câu biến thể khi cần tạo ngay	Trả về lỗi tạm thời khi học sinh yêu cầu bắt đầu lượt làm lại.
Kết quả job hết thời gian lưu trong redis trước khi được thu hoạch	Với câu hỏi của đề, hệ thống giao lại job và tính vào giới hạn ba lần thử. Với câu biến thể được chuẩn bị trước, hệ thống giao lại job khi học sinh mở màn hình chữa bài; nếu học sinh đang mở lượt làm lại thì tạo câu biến thể ngay trong yêu cầu đó.
Câu hỏi được tạo ra không hợp lệ hoặc trùng nội dung	Yêu cầu tạo lại theo cơ chế của từng loại câu hỏi. Với câu của đề, hệ thống dừng sau tối đa ba lần thử và lưu lý do thất bại, nhưng chưa hiển thị lý do này trên giao diện. Nếu đang thay thế câu hỏi, câu cũ vẫn được giữ lại.

Tiếp trang sau

Tình huống lỗi	Cách xử lý
Job soạn câu hỏi thất bại hoàn toàn	Giao lại vị trí câu hỏi tương ứng, tính vào giới hạn ba lần thử; hết lượt thì dừng và lưu lý do thất bại. Nếu đang thay thế câu hỏi, hệ thống giữ nguyên câu cũ.
Kết nối SSE và thông báo	
Không nhận được nội dung mới trong thời gian chờ khi trả lời học sinh	Gửi event báo lỗi qua SSE và không lưu câu trả lời chưa hoàn chỉnh.
Lượt hội thoại gặp lỗi hoặc bị từ chối sau khi kết nối SSE đã thiết lập	Gửi event kết thúc kèm thông báo lỗi, do kết nối đã mở nên không thể trả về mã trạng thái HTTP khác.
Mất kết nối đến channel thông báo soạn đề hoặc không nhận được thông báo trong 180 giây	Dừng lắng nghe, thực hiện thu hoạch kết quả thêm một lần và tiếp tục tổng hợp kết quả để phản hồi cho giáo viên.
Khóa hội thoại	
Giáo viên đóng thẻ trình duyệt trong khi hội thoại đang xử lý	Giải phóng khóa hội thoại khi quá trình xử lý kết thúc.
Tiến trình `backend` dừng đột ngột khi hội thoại đang bị khóa	Khóa có thời hạn mặc định mười phút và tự hết hiệu lực khi quá thời hạn, tránh khiến hội thoại bị khóa vĩnh viễn.
Xử lý tài liệu	
Không thể đưa job xử lý tệp vào hàng đợi	Cập nhật trạng thái tài liệu thành thất bại và lưu lý do lỗi.
Tài liệu đang xử lý nhưng không có cập nhật tiến độ trong hơn 300 giây	Hiển thị trạng thái xử lý thất bại khi đọc dữ liệu, nhưng không thay đổi trạng thái đang lưu trong database.

7.1.5 Toàn cảnh một lượt hội thoại của giáo viên

Hình 7.6 tóm ba hình 7.1, 7.2 và 7.3 thành một lượt hội thoại trọn vẹn; chi tiết của từng pha nằm ở hình tách.



Hình 7.6: Một lượt hội thoại của giáo viên, qua SSE

7.2 Agent

7.2.1 Vai trò và trách nhiệm

`agent` là service viết những nội dung cần tới mô hình ngôn ngữ: câu hỏi của đề, câu biến thể, câu trả lời cho học sinh ở giai đoạn 2, đề xuất bước tiếp theo trong hội thoại của giáo viên, lời kể lại kết quả một plan, và tên một đoạn hội thoại. Để viết, nó gọi **Model Provider** (nhà cung cấp mô hình). Ngoài Model Provider, nó chỉ gọi thêm một thứ nằm ngoài hệ thống: Jev, mô hình phân loại của TypeSafe AI. Mỗi lần gọi mô hình đều gửi kèm một *lời dặn*, tức đoạn chữ hướng dẫn mô hình phải viết gì; trong hội thoại của giáo viên, Jev chọn phần nào của lời dặn được nạp.

`agent` không nhận lời gọi nào từ bên ngoài và không có quyền vào database. Nó là một worker ngồi nghe queue của mình: `backend` giao job, `agent` viết, rồi đặt kết quả vào `redis` để `backend` lấy về. Vì không tra được database, mỗi job phải tự mang mọi thứ nó cần: job trả lời học sinh mang theo mọi câu em làm sai, kèm các phương án, lời giải, đáp án đúng và phương án em đã chọn, chứ không mang một mã câu hỏi rồi tự đi tra.

Thứ agent trả về chỉ là nội dung, không bao giờ là một quyết định: không điểm, không độ tin cậy, không kết luận học sinh đã hiểu hay chưa. Nó cũng không tự chạy gì: một tool hay một plan nó đề xuất chỉ chạy khi backend chạy nó. Dùng nội dung ấy thế nào, ghi hay bỏ, là việc của backend. Ngoài giá trị trả về, agent còn phát hai thứ qua pub/sub: từng mảnh chữ của câu trả lời cho học sinh, và thông báo mỗi khi viết xong một câu cho đề đang soạn.

7.2.2 Nhận job, gọi mô hình và trả kết quả

agent nhận job của năm task. Mọi lần nó gọi mô hình để viết chữ đều nằm trong một **graph** (chuỗi hàm cố định) dựng bằng thư viện LangGraph; hai task soạn câu dùng chung một graph. Bảng 7.4 cho biết mỗi task chạy graph nào, graph ấy gồm những hàm nào, gọi mô hình mấy lần và trả về gì; còn khi nào mỗi task được giao thì bảng 6.3 đã nói.

Bảng 7.4: Năm task của agent: graph, các hàm, số lần gọi mô hình, và thứ trả về

Task	Graph	Các hàm	Gọi mô hình	Trả về
write_draft_question	authoring	Viết rồi tự kiểm; câu chưa đạt thì gửi lý do về cho hàm viết	Một tới ba lần	Một câu hỏi
generate_retry_question	authoring	Như trên	Một tới ba lần	Một câu biến thể
explain_turn	explain	Dựng lời dặn từ những câu em làm sai, rồi gửi cho mô hình	Một lần, trả chữ dần	Câu trả lời cho học sinh
propose_next_step	propose	Dựng lời dặn, rồi gọi mô hình chọn một đề xuất	Một hay hai lần, sau khi Jev chọn tệp lời dặn	Một đề xuất: trả lời, hỏi giáo viên, dàn ý, tool, hay plan; hay lời kể lại sau một plan
name_conversation	naming	Một hàm	Một lần	Tên đoạn hội thoại

Graph và hàm. Mỗi hàm của graph làm một phần của job rồi trao kết quả cho hàm sau. Hàm nhận job, nói ở đoạn dưới, không thuộc graph nào: đó là hàm worker gọi khi lấy một job xuống, và chính nó chạy graph.

Ba lối ra của một job. Mỗi task có một hàm nhận job, và cả năm hàm đi cùng một đường. Mô hình bị tắt trong cấu hình thì hàm trả *nội dung dọn trước*, tức nội dung mã nguồn tự dựng mà không cần mô hình: một câu viết sẵn, hay vài chữ ghép từ chính job, như sáu chữ đầu của

tin nhắn làm tên đoạn hội thoại; mô hình bật thì hàm chạy graph; graph hỏng thì hàm quay về nội dung dọn trước, trừ hai hàm: hàm soạn câu của đề để job hỏng, còn hàm đề xuất trả một thông báo hệ thống. Hàm viết câu biến thể chỉ có nội dung dọn trước khi câu gốc thuộc bộ câu dọn trước và còn biến thể chưa dùng; không thì job của nó cũng hỏng, kể cả khi mô hình tắt. Thà có một câu dọn trước còn hơn một tính năng từ chối chạy, nhưng lựa chọn ấy có cái giá: câu dọn trước không mang dấu nào để `backend` nhận ra nó, nên ba hàm vừa kể đã thôi lùi về nó khi không chắc nó đúng. Riêng hàm trả lời học sinh: đã phát được vài chữ rồi mới hỏng thì nó trả về đúng những chữ đã phát làm câu trả lời, không thay bằng câu dọn trước, vì học sinh đã thấy chúng trên màn hình.

Đăng ký task và thông báo. Năm task được đăng ký dưới đúng tên khai trong gói dùng chung `contracts`, không dưới tên hàm, nên đổi tên một hàm không làm gãy lời giao job của `backend`. Thông báo một câu soạn xong chỉ được phát ngay sau khi kết quả đã ghi vào `redis`: hàm nhận job chỉ đặt sẵn thông báo; worker ghi kết quả vào `redis` khi hàm trả về, rồi mới phát thông báo. Phát sớm hơn thì `backend` nhận thông báo, đi thu hoạch, và chỉ gặp một kết quả chưa có. Thông báo chỉ mang số thứ tự của câu, không mang câu: pub/sub không giữ lại gì, nên thông báo lạc thì câu vẫn nằm trong kết quả của job và `backend` vẫn thu hoạch được. Phát hỏng thì bỏ qua, và job vẫn được tính là xong.

Nối mô hình. Chỉ một tệp, `llm.py`, biết đang gọi Model Provider nào, nên đổi Model Provider chỉ là sửa cấu hình; Jev thì đi qua một tệp riêng. `llm.py` đặt trần thời gian mặc định hai mươi giây cho mỗi lần gửi tới Model Provider, và xếp một mô hình dự phòng sau mô hình chính nếu cấu hình có. Hai graph soạn câu và đề xuất bước tiếp theo bắt mô hình trả lời theo một khuôn JSON cố định, tức một bộ ô có tên sẵn mà mô hình phải điền, như đề bài, các phương án, lời giải; ba graph còn lại nhận chữ thường. Chữ trong khuôn — câu hỏi soạn ra, lời nói của một đề xuất, tên các việc của plan, dàn ý — còn đi qua một bộ dựng lại ký hiệu toán. Mô hình viết toán bằng LaTeX, mà trong một chuỗi JSON, dấu gạch chéo đứng trước f, n, r, t hay b là mã của một ký tự điều khiển, nên `\frac` về tới nơi thành một ký tự điều khiển cộng với "rac". Lỗi này đã lọt vào database thật ngày 05/10/2026. Bộ dựng lại đi theo một danh sách lệnh LaTeX đã biết, nên một lệnh không có trong danh sách thì để nguyên, chứ không bị đoán sai.

7.2.3 Xử lý các task chính

Bốn phần dưới đây đi qua bốn nhóm task. Mỗi phần nói `agent` nhận gì, viết gì, và thứ nó viết được kiểm ở đâu, nếu có; `backend` làm gì với kết quả thì mục 7.1 đã nói.

Soạn câu hỏi và câu biến thể. Hai task này dùng chung graph soạn câu, chỉ khác lời dặn. Job soạn một câu của đề mang mục dàn ý sinh ra câu ấy: kiến thức cần kiểm, công thức và cách làm, đúng như giáo viên đã đọc. Các job của một lần soạn chạy song song và không thấy nhau, nên mỗi job còn được biết mình là câu thứ mấy và kiến thức của các câu khác để khỏi hỏi sang, và mang đề bài của những câu đã có trong đề để phép tự kiểm loại một câu lặp lại; nếu vẫn trùng thì `backend` bắt khi thu hoạch. Job câu biến thể mang câu gốc, phương án học sinh đã chọn và lỗi em mắc, cùng đề bài của các lượt trước; đề bài câu gốc và các lượt ấy đều bị cấm lặp. Lời dặn đòi một câu cùng dạng và cùng cách làm nhưng khác số liệu, có một phương án nhiễu ứng với đúng lỗi ấy. Viết xong, câu qua hàm tự kiểm, xét bốn điều: đúng một đáp án đúng, mọi phương án nhiễu gắn một lỗi, ít nhất hai lời giải, và đề bài không trùng một đề bài bị cấm. Câu không đạt thì lý do được gửi về cho hàm viết để viết một câu

khác; sau ba lần vẫn không đạt thì job câu của đề hỏng, còn job câu biến thể trả một biến thể dọn trước nếu còn, không thì cũng hỏng. Phép tự kiểm này không thay phép kiểm của `backend`, vốn rộng hơn; nó chỉ để một câu sai hình dạng không phải đi tới `backend` rồi bị giao lại. Hình 7.4 đặt hai phép kiểm ấy trên cùng một đường đi.

Trả lời học sinh. Mỗi tin nhắn của học sinh là một job và một lần gọi mô hình. Lời dặn yêu cầu trợ lí giải thích chứ không kết luận — không cho điểm, không nói em đã hiểu — và dùng đúng nhãn lỗi đã gắn sẵn cho phương án em chọn từ lúc soạn đề thay vì tự chẩn đoán lại, để hai học sinh mắc cùng một lỗi được giải thích theo cùng lỗi ấy. Trong lúc mô hình viết, hàm nhận job phát từng mảnh chữ lên channel mà `backend` đang nghe; khi job xong, cả câu trả lời vẫn được trả về, và đó mới là thứ được lưu.

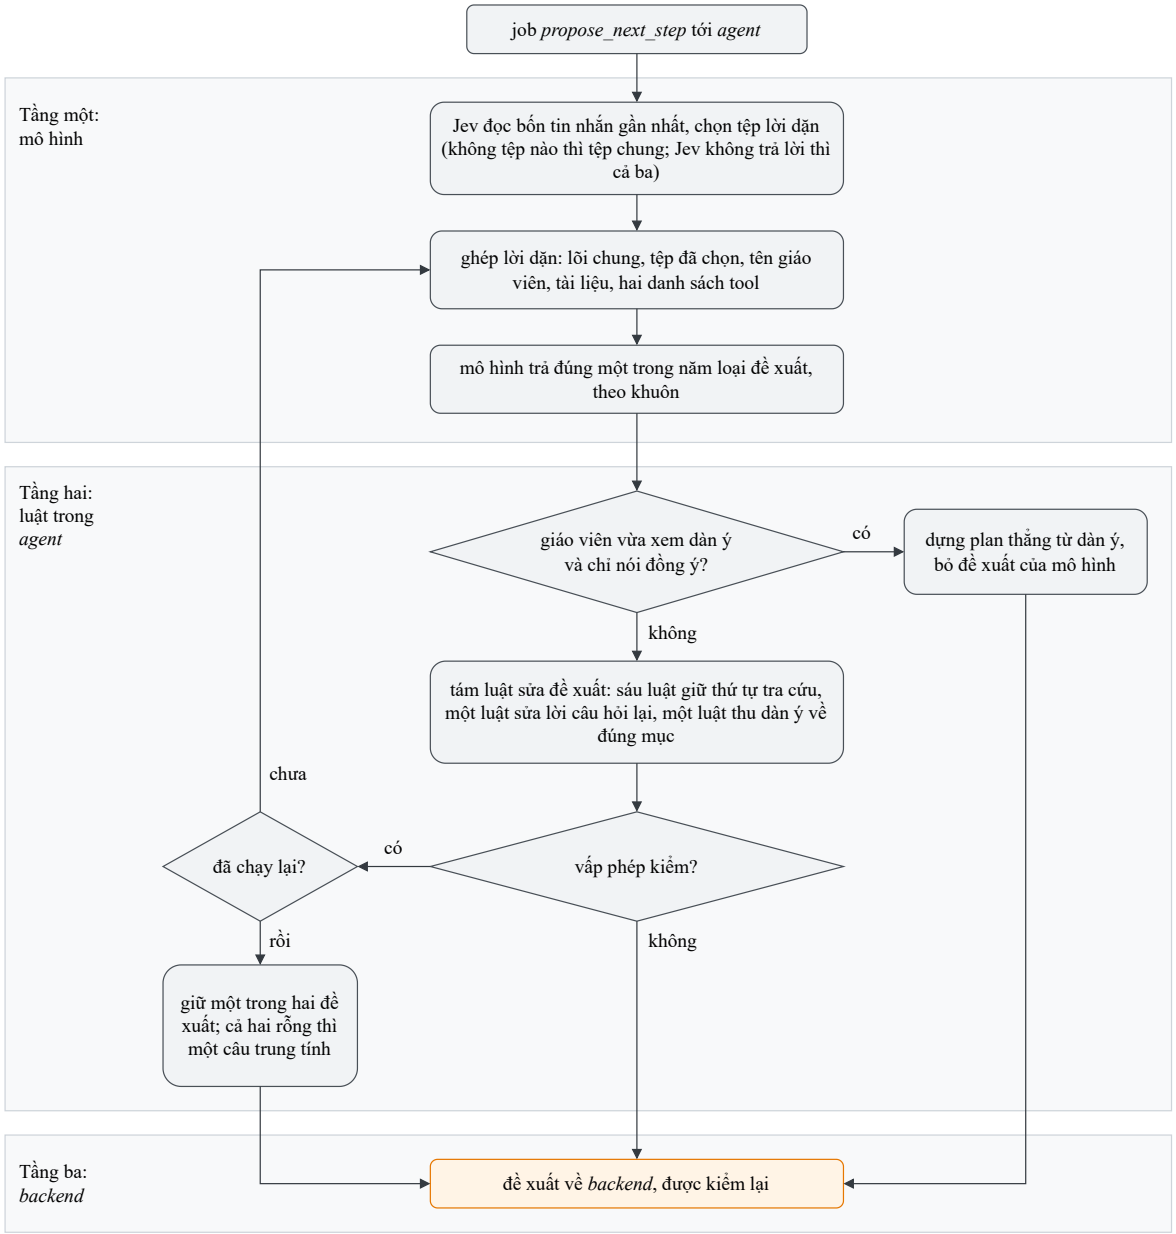
Đề xuất bước tiếp theo. Đây là task phức tạp nhất: graph đề xuất chiếm hơn một phần ba mã nguồn và ít nhất một nửa số ca kiểm thử của `agent`. Mỗi bước của pha 1 trong hình 7.6 là một job của task này, và đề xuất của nó đi qua ba tầng, mỗi tầng bắt một loại sai khác. Hình 7.7 vẽ ba tầng ấy.

Tầng một là chính mô hình, đề xuất trong một khuôn. Lời dặn của task này không viết liền một khối: phần chỉ một loại việc cần nằm trong ba *tệp lời dặn*, một cho việc tra lớp và kết quả, một cho việc soạn đề, và một tệp chung. Trước khi graph chạy, Jev đọc bốn tin nhắn gần nhất và trả lời có hay không cho từng tệp chuyên biệt; không tệp nào được chọn thì nạp tệp chung, còn Jev không trả lời được thì nạp cả ba. Lời dặn gửi mô hình ghép từ một lõi chung, các tệp vừa chọn, tên giáo viên, tài liệu đang đính kèm, và hai danh sách tool: tool gọi được ngay, và tool chỉ nêu được trong plan. Những luật mà lượt hội thoại nào cũng cần nằm trong lõi, vì Jev chọn sai thì một tệp vắng mặt. Mô hình trả về đúng một trong năm loại đề xuất: trả lời, hỏi giáo viên, đưa ra dàn ý, gọi một tool, hay nêu plan. Khuôn chỉ có những ô có tên sẵn, nên một đề xuất sai hình dạng không qua được tầng này.

Khuôn chỉ hỏi những gì mô hình trả lời được, vì mỗi ô là một câu hỏi đặt cho nó, và không ô nào được để ngỏ. Bài học ấy có giá: khuôn đầu tiên là nguyên kiểu dữ liệu `agent` trả cho `backend`, nên hỏi cả những thứ mô hình không thể biết, như mã của job, và có một ô tham số nhận bất cứ thứ gì. Model Provider từ chối thẳng mọi lần gọi vì ô ấy, và nội dung dọn trước che kín chuyện đó sau một câu trả lời nghe hợp lý.

Tầng hai là tám luật trong `agent`, sửa đề xuất ngay sau khi mô hình trả lời. Sáu luật giữ thứ tự tra cứu, phần lớn quanh tài liệu: plan mở đầu bằng một tool tra cứu thì tool ấy được gọi trước, chưa đọc mục lục thì chưa được nêu plan soạn theo tài liệu, chưa đọc chữ của phần ấy thì chưa được đưa ra dàn ý. Một đề xuất đến sớm như vậy thành một lời gọi tool tra cứu, với tham số lấy từ chính đề xuất hay từ những gì đã có trong hội thoại, không đoán thêm; ở bước sau, mô hình nêu lại với kết quả trong tay. Luật thứ bảy sửa lời một câu hỏi lại đứng ngay sau danh sách tài liệu, cho khớp các nút giáo viên sẽ bấm. Luật thứ tám sửa mục đích của một dàn ý: giáo viên nói rõ là thay câu thứ ba mà dàn ý lại viết cho cả một đề mới thì dàn ý được thu về đúng mục chứa câu ấy. Riêng khi giáo viên vừa được xem dàn ý và trả lời bằng một câu chỉ gồm lời đồng ý, như "ok" hay "được", thì `agent` dựng plan thẳng từ dàn ý và bỏ đề xuất của mô hình, vì sau một chữ "ok" mô hình hay quên phạm vi vừa bàn.

Trước và sau các luật sửa là các phép kiểm: plan thiếu tham số bắt buộc, đúng luật `backend` dùng khi kiểm plan, hay có ký tự điều khiển trong tham số; dàn ý rỗng, hay có tổng số câu khác số câu mô hình vừa ghi nhận; câu hỏi lại giáo viên có quá ít lựa chọn; hay một đề xuất không có chữ nào. Đề xuất vấp một phép kiểm thì `agent` chạy lại graph thêm đúng một lần.



Hình 7.7: Ba tầng một đề xuất bước tiếp theo đi qua

Lần hai vẫn vấp thì nó giữ lại một trong hai đề xuất để backend xét, chứ không tự bịa tham số hay lựa chọn; hai lần đều rỗng thì nó trả một câu trung tính nhờ giáo viên nói lại.

Tầng ba là backend: đề xuất về tới đó vẫn chỉ là đề xuất, và đoạn *Điều phối lượt hội thoại của giáo viên* ở mục 7.1 đã kể nó được kiểm những gì.

Kể lại và đặt tên. Lời kể lại kết quả một plan là một vòng nữa của task đề xuất, không phải một job riêng: backend chỉ cấp cho nó các tool tra cứu, trong đó có last_plan kể gọn plan vừa chạy, việc nào xong, việc nào hỏng, việc nào không chạy, và không cấp tool nào để nêu plan, nên nó không thể đề xuất thêm việc. Số câu đã soạn nằm trong kết quả của last_plan, dựng từ con số backend đếm trong database. Mô hình nói một câu thì câu ấy là câu kết, im lặng thì lượt kết thúc không câu kết; lời dặn cấm nói quá điều đã làm (chỗ hở của luật này ở mục 7.2.6). Đặt tên cho một đoạn hội thoại là task nhỏ nhất: một hàm, nhận câu mở đầu của giáo viên và trả về một cái tên ngắn. Ở đây backend có phép kiểm thật: cái tên phải có ít nhất một từ chung với câu mở đầu, không thì backend dùng chính câu mở đầu, đã làm gọn.

7.2.4 Các ràng buộc và cơ chế kiểm soát

Bảng 7.5 tổng hợp các ràng buộc agent giữ, cơ chế thực thi mỗi ràng buộc, và cách kiểm chứng. Không có ràng buộc database, vì agent không có database.

Bảng 7.5: Ràng buộc agent giữ, cơ chế thực thi, và cách kiểm chứng

Ràng buộc	Cơ chế thực thi	Kiểm chứng
Phân quyền		
Kết quả chỉ mang nội dung, không mang quyết định nào, kể cả trong các trường lồng nhau	Kiểu dữ liệu trả về của mọi task chỉ có nội dung	kiểm thử tự động
Không có quyền vào database	Mã nguồn không nhắc tới thư viện hay thông tin kết nối database nào	check_contract
Lời kể lại không cầm tool nào để nêu plan	backend gọi lượt kể lại với danh sách tool nêu plan rỗng	check_contract
Tính hợp lệ		
Câu hỏi đúng hình dạng	Phép tự kiểm trong graph soạn câu; backend kiểm lại khi thu hoạch	kiểm thử tự động
Chữ trong khuôn đi qua bộ dựng lại ký hiệu toán	latex_escapes, ở graph soạn câu và graph đề xuất	check_contract
Tính nhất quán		
Task đăng ký dưới đúng tên trong contracts	Danh sách task của worker	kiểm thử tự động

tiếp trang sau

Ràng buộc	Cơ chế thực thi	Kiểm chứng
Thông báo câu soạn xong phát sau khi kết quả đã ghi, chỉ mang số thứ tự	Worker phát thông báo khi job đã kết thúc	kiểm thử tự động
Câu trả lời bị cắt giữa chừng giữ đúng những chữ đã phát	Hàm nhận job của task trả lời học sinh	kiểm thử tự động
Thời gian		
Một job, kể cả lời chọn của Jev và các lần graph gọi lại mô hình, kết thúc trước khi `backend` thôi lấy kết quả	So cấu hình hai service: Jev 3 giây + 20 giây × 3 lần gọi = 63 giây, dưới 70 giây	`check_contract`

Ca kiểm thử "không mang quyết định" chạy mọi task hai lần, với mô hình tắt rồi bật, và mô hình giả dùng khi kiểm thử dựng được đầu ra theo khuôn, nên đầu ra thật của graph soạn câu và graph đề xuất cũng bị soi. Phép kiểm thời gian thì được kiểm chứng hẹp hơn lời của nó: nó coi hai mươi giây là trần của cả một lần gọi, trong khi đó chỉ là trần của một lần gửi: thư viện của OpenAI tự gửi lại tới hai lần khi quá giờ, rồi mới tới mô hình dự phòng. Một lần gọi vì thế có thể dài hơn sáu mươi giây, và `backend` có thể thôi lấy kết quả trong lúc worker vẫn đang viết.

7.2.5 Xử lý lỗi

Bảng 7.6 nói `agent` làm gì khi mô hình hay Jev hỏng, hay khi thứ mô hình viết vấp phép kiểm, theo từng nhóm task. Đường lùi chung là nội dung dọn trước, trừ các ngoại lệ, như đoạn *Ba lối ra của một job* đã nói; bảng cho thấy nó trông thế nào ở từng task.

Bảng 7.6: Khi một thao tác bên trong `agent` hỏng

Khi	`agent` làm gì
Mọi task	
Mô hình quá giờ hay báo lỗi	Gọi mô hình dự phòng nếu cấu hình có; vẫn hỏng thì xử lý theo từng task dưới đây
Soạn câu hỏi và câu biến thể	
Câu vấp phép tự kiểm	Gửi lý do về để viết lại; hàm viết chạy tối đa ba lần, vẫn vấp thì xử lý như mô hình hỏng
Mô hình hỏng khi soạn một câu của đề	Để job hỏng, không câu dọn trước nào thay chỗ; `backend` giao lại vị trí ấy, tính vào ba lần thử
Mô hình hỏng khi viết câu biến thể	Câu gốc thuộc bộ câu dọn trước và còn biến thể chưa dùng thì trả biến thể ấy; không thì để job hỏng, và yêu cầu mở lượt đang chờ câu ấy nhận lỗi
Phát thông báo câu soạn xong hỏng	Bỏ qua; job vẫn xong, và `backend` vẫn thu hoạch được câu
Trả lời học sinh	

tiếp trang sau

Khi	agent làm gì
Mô hình hỏng trước khi phát chữ nào	Trả một câu trả lời dọn trước
Mô hình hỏng giữa chừng	Trả đúng những chữ đã phát làm câu trả lời
Đề xuất bước tiếp theo	
Jev chưa được cấu hình, báo lỗi, quá 3 giây, hay trả lời một hình dạng lạ	Nạp cả ba tệp lời dặn
Đề xuất vấp phép kiểm	Chạy lại graph đúng một lần và giữ đề xuất lần hai, trừ ba trường hợp: lần đầu có đề xuất mà lần hai rỗng hay mô hình hỏng thì giữ lần đầu; cả hai là câu hỏi quá ít lựa chọn thì giữ lần nhiều lựa chọn hơn; cả hai đều rỗng thì trả một câu trung tính nhờ giáo viên nói lại
Mô hình hỏng	Trả một thông báo hệ thống nhờ giáo viên gửi lại sau; đề xuất dọn trước chỉ dùng khi mô hình tắt
Kể lại và đặt tên	
Mô hình hỏng khi kể lại	Trả một câu hệ thống; `backend` bỏ câu ấy và lưu thông báo của riêng nó, không có câu kết
Mô hình hỏng khi đặt tên	Lấy sáu chữ đầu của câu mở đầu

7.2.6 Các giới hạn hiện tại

Hai yêu cầu dưới đây đã được đặt ra cho hệ thống, nhưng `agent` mới thực thi một phần hoặc chưa thực thi. Mỗi yêu cầu có một chỗ hở cụ thể:

- **Lời kể lại không nói quá điều đã làm** — chỉ lời dặn canh điều này. Con số trên màn hình do `backend` tự đếm nên không sai theo, nhưng câu mô hình viết đi thẳng lên màn hình mà không ai so lại.
- **Giáo viên đồng ý dàn ý trước khi câu được soạn** — luật trong `agent` chỉ bắt câu chỉ gồm lời đồng ý; câu khác thì đề xuất của mô hình đi nguyên, và mô hình có thể đọc "ok nhưng đổi câu 2" thành đồng ý rồi nêu plan soạn câu. `backend` chỉ chứng minh được dàn ý đã hiện ra cho giáo viên, nên plan ấy vẫn đi qua.

7.3 Document

7.3.1 Vai trò và trách nhiệm

`document` đọc những tệp giáo viên tải lên và dựng cây mục lục cho chúng; một tài liệu chỉ dùng được khi có đủ cả hai. Service này gồm hai worker, không nhận lời gọi nào từ bên ngoài và không có quyền vào database. Job tới mang địa chỉ của tệp trong object store, không mang byte của tệp; worker tự lấy byte về để đọc.

Mọi thứ `document` đọc ra và dựng nên đều nằm ở content store: chữ của từng trang, gọi là

bản thô, cây mục lục, và các **chunk** (mẩu chữ ngắn) dưới từng nút của cây, chia vào sáu **collection** (nhóm bản ghi cùng loại, như một bảng của database). Còn kết quả xử lý và tiến độ thì `document` không ghi vào database: nó gửi chúng đi thành job trên queue của `ingest`, và `ingest` mới là bên ghi.

Để dựng cây, `document` gọi hai thứ nằm ngoài hệ thống, cũng là hai thứ `agent` gọi: Model Provider, để đọc tên chương trên ảnh và tóm tắt từng nút của cây, và Jev, để quyết mỗi dòng có dáng tiêu đề thật ra là gì và thuộc cấp nào của cây. Mặc định, `gpt-5.6-luna` đọc tên chương và `gpt-4o-mini` viết tóm tắt; mỗi mô hình đổi được sang một mô hình Claude bằng cấu hình. Còn **OCR** (đọc chữ từ ảnh) thì không gọi ra ngoài: ba mô hình của nó chạy ngay trong worker đọc tệp.

7.3.2 Hai worker, ba task và sáu collection

`document` nhận job của ba task, và hai trong số đó nó tự giao cho mình (bảng 7.7): một bản chụp được đọc thành nhiều *lô*, mỗi lô tối đa mười trang và là một job `ocr_pages`, rồi cây được dựng trong một job `index_document`. Ra khỏi service thì nó chỉ gửi job của hai task, cả hai lên queue của `ingest`: `document_progress` báo tiến độ, `document_probed` mang kết quả cuối cùng của một tệp.

Bảng 7.7: Ba task của `document`: worker nào nhận, ai giao, và job gửi đi

Task	Worker nhận	Ai giao	Gửi đi
`probe_document`	Đọc tệp	`backend`, khi giáo viên tải tệp lên	Tệp có sẵn chữ: `index_document`, sau khi đã ghi bản thô. Bản chụp: lô `ocr_pages` đầu tiên. Tệp hỏng hay rỗng: `document_probed` kèm lý do
`ocr_pages`	Đọc tệp	Chính worker đọc tệp	`document_progress` sau mỗi lô trừ lô cuối; rồi lô kế, hay sau lô cuối `index_document` nếu cả cuốn có chữ; `document_probed` khi cả cuốn không ra chữ nào, hay một trang không đọc nổi
`index_document`	Dựng cây	Worker đọc tệp	`document_progress` trong lúc dựng; `document_probed` khi cây đã ghi xong, hay khi dựng hỏng

Vì sao có hai worker. Đọc tệp tốn bộ xử lý, còn dựng cây tốn thời gian gọi Jev và Model Provider qua mạng. Worker đọc tệp vì vậy chạy một job một lúc: OCR chiếm trọn bộ xử lý, nên hai lô chạy song song chỉ tranh nhau rồi cùng chậm. Nó nạp ba mô hình OCR một lần lúc khởi động, mất năm tới sáu giây, vì nạp lại ở mỗi lô là tốn thêm năm, sáu giây ấy cho từng lô của một cuốn. Worker dựng cây không nạp mô hình nào và chạy tới bốn job song song. Gộp làm một worker thì phải chọn: chạy một job một lúc thì job dựng cây xếp sau mọi lô OCR, chạy nhiều job thì các lô OCR tranh bộ xử lý. Cái giá của việc chỉ chạy một job một lúc nằm ở mục 7.3.6.

Tự giao job và báo tiến độ. Job của một lô OCR mang một mã cố định ghép từ tài liệu và trang đầu của lô; job dựng cây mang một mã cố định theo tài liệu. Một lô bị chạy lại sau khi đã giao lô kế thì lần giao thứ hai bị từ chối, nên một cuốn không có hai chuỗi lô đọc song song, cũng không có hai job dựng cùng một cây. Mã chỉ chặn trùng khi job kia còn trên queue hay đang chạy, nên điều này chỉ đúng khi có một worker đọc tệp, như hiện nay. Worker dựng cây báo tiến độ ngay trong lúc dựng — sau khi nạp bản thô, sau mỗi tên chương đọc được, sau khi Jev xếp xong, và trong lúc tóm tắt — để `backend` không đọc một cuốn đang dựng ra là hỏng sau ba trăm giây; dòng trạng thái khi ấy hiện "Đang dựng mục lục…".

Sáu collection. Bảng 7.8 kể sáu collection, ai ghi và ai đọc. Chỉ `document` ghi content store; `backend` chỉ đọc cây và các chunk, khi hội thoại của giáo viên cần tới.

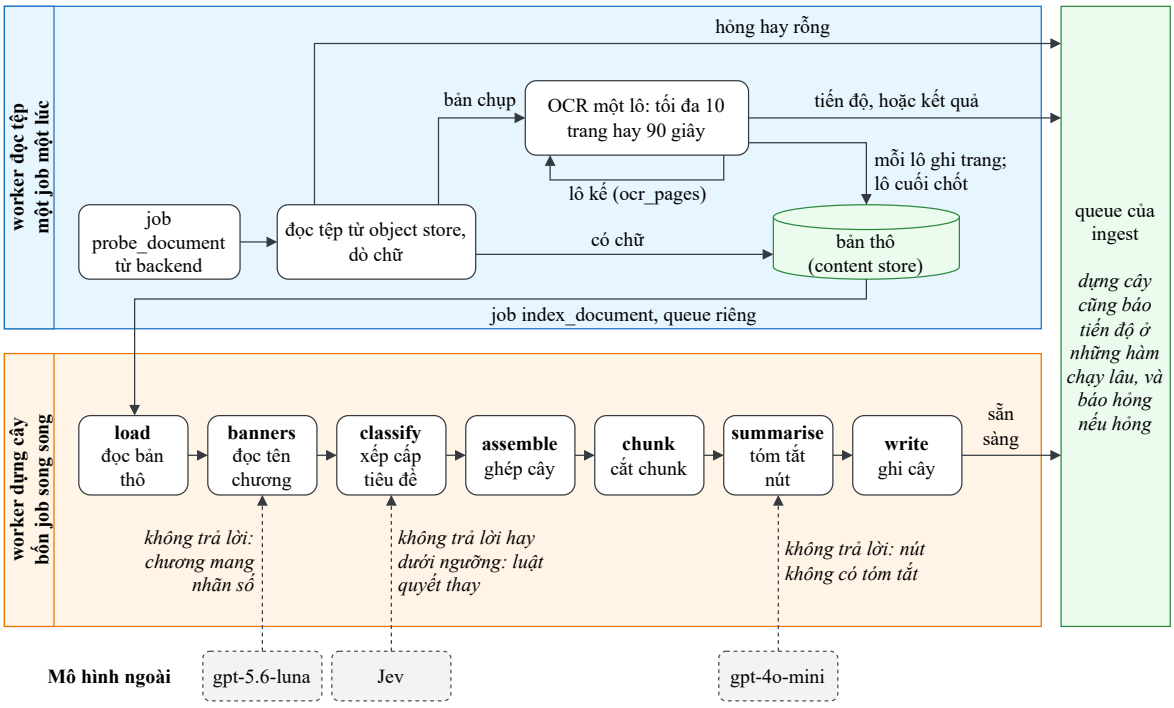
Bảng 7.8: Sáu collection của content store: giữ gì, ai ghi, ai đọc

Collection	Giữ gì	Ai ghi	Ai đọc
`documents`	Bản ghi chung của bản thô, khác bảng cùng tên của database: đọc thẳng chữ có sẵn hay qua OCR, đã đọc xong chưa	Worker đọc tệp	Worker dựng cây
`pages`	Chữ của từng trang, chia theo khối	Worker đọc tệp	Worker đọc tệp, để bỏ qua trang đã đọc; worker dựng cây
`indexes`	Bản ghi chung của cây (số nút, số chunk, cách xếp), ghi sau cùng	Worker dựng cây	Worker dựng cây, `backend`
`nodes`	Các nút của cây mục lục	Worker dựng cây	`backend`
`chunks`	Các chunk của mỗi nút	Worker dựng cây	`backend`
`block_labels`	Quyết định cho từng dòng có dáng tiêu đề: ai quyết, Jev đã phân vân giữa những gì; để gỡ lỗi và đo	Worker dựng cây	Không ai, lúc chạy

7.3.3 Một tệp đi qua service

Hình 7.8 vẽ đường đi của một tệp qua hai worker, từ lúc worker đọc tệp lấy job dò tệp xuống tới lúc kết quả sẵn sàng rời service.

Dò tệp. Worker đọc tệp lấy byte của tệp từ object store rồi dò xem tệp có sẵn chữ không. Tệp `.txt` và `.md` phải là UTF-8, hay UTF-16 có BOM; bảng mã khác bị từ chối chứ không đoán, vì đoán sai thì ra chữ trông như chữ mà sai dấu. Với tệp PDF, nó đếm số trang có chữ, và một trang tính là có chữ khi có từ một trăm ký tự trở lên: từ mười phần trăm số trang có chữ trở lên thì tệp có sẵn chữ, còn lại là bản chụp. Một PDF không có trang nào được báo là không có chữ, không đi OCR. Đếm trang chứ không lấy trung bình ký tự là có chủ ý: một bản



Hình 7.8: Một tệp đi qua `document`: hai worker, ba mô hình ngoài, và các đường lùi

chụp dày mà riêng trang mục lục có sẵn chữ, đủ nhiều để kéo trung bình lên quá một trăm ký tự một trang, vẫn được nhận ra là bản chụp.

Bản chụp đọc theo lô. Một bản chụp được đọc qua nhiều job, mỗi job một lô: tối đa mười trang, và lô đã chạy quá chín mươi giây thì không mở trang mới, để lô không chạm trần một trăm hai mươi giây của worker. Mỗi lô ghi trang của nó vào content store; một lô bị chạy lại thì chỉ đọc những trang chưa có trong content store. Mỗi trang đi qua năm *chặng*, tức năm công đoạn nối tiếp nhau của OCR: dựng ảnh, nhận khối, tìm dòng, đọc chữ từng dòng, rồi gán dòng vào khối. Hai chặng nhận khối và tìm dòng dùng mô hình của PaddleOCR, còn chặng đọc chữ dùng một bộ đọc khác, mặc định là EasyOCR, vì bộ đọc chữ của PaddleOCR không phát ra một số chữ tiếng Việt mang hai dấu, như "ế" hay "ộ". Công thức toán không được đọc riêng. Trên một bộ đo năm mươi trang có năm mươi tám công thức, mô hình đọc công thức từng được thử chỉ đọc đúng chín: hai mươi bốn công thức đã hỏng từ chặng nhận khối, nên mô hình nào đứng sau cũng không cứu được, mô hình ấy đọc sai thêm hai mươi mốt, và bốn công thức còn lại hỏng mà chưa rõ do đâu. Khối công thức vì vậy chỉ nhận chữ OCR như mọi khối khác.

Bản thô ghi trước. Đọc xong, bản thô của tệp, chia theo trang và theo khối, đã nằm trong content store. Tài liệu lúc này *chưa* sẵn sàng, vì nó còn cần cây mục lục. Worker đọc tệp giao một job `index_document` lên queue riêng của worker dựng cây, và chưa gửi kết quả nào về `ingest`.

Bảy hàm dựng cây. Job dựng cây chạy một graph gồm bảy hàm nối thẳng (bảng 7.9). Mô hình không tự dựng cây: hàm `assemble` ghép cây bằng mã nguồn, từ quyết định của hàm `classify`. Mô hình chỉ góp phần vào ba hàm, và cả ba đều có đường lùi ngay bên trong hàm: mô hình không trả lời, hay chưa được cấu hình, thì tài liệu vẫn sẵn sàng, chỉ kém hơn.

Bảng 7.9: Bảy hàm dựng cây mục lục, và đường lùi của những hàm có gọi mô hình

Hàm	Làm gì	Mô hình không trả lời thì
`load`	Đọc bản thô; bản thô chưa đọc xong thì dừng cả job	—
`banners`	Chỉ với bản chụp: đọc tên chương trên ảnh rộng ở đầu trang, khi chữ OCR trong ảnh có CHƯƠNG hay PHẦN, bằng Model Provider (mặc định `gpt-5.6-luna`)	Chương mang nhãn số
`classify`	Xếp vai trò và cấp cho từng dòng có dáng tiêu đề; luật và Jev cùng quyết, Jev thắng khi đủ chắc	Luật quyết thay
`assemble`	Ghép cây tối đa ba cấp, không nhảy cấp; tiêu đề sâu hơn gộp vào nút cha	—
`chunk`	Cắt chữ thành các chunk dưới từng nút	—
`summarise`	Tóm tắt từng nút, từ cấp sâu nhất lên; nút cha tóm từ tóm tắt của các con, bằng Model Provider (mặc định `gpt-4o-mini`)	Nút không có tóm tắt
`write`	Ghi cây vào content store	—

Ở hàm `classify`, luật và Jev cùng đưa ra một quyết định cho mỗi dòng có dáng tiêu đề, và Jev chỉ thắng khi độ tin cậy của nó từ tám mươi phần trăm trở lên, một ngưỡng cấu hình được. Jev được hỏi riêng cho từng dòng, và chỉ một lời gọi hỏng là luật quyết cả cây, để cây không nửa Jev nửa luật. Tóm tắt của mỗi nút là để trợ lí, khi đọc mục lục, chọn đúng chương hay bài chỉ bằng tiêu đề và tóm tắt, chưa phải đọc chữ của nút. Vì sao chưa nói được Jev đã làm cây tốt hơn hay chưa thì nằm ở mục 7.3.6.

Ghi cây rồi mới báo sẵn sàng. Hàm cuối ghi các nút, các chunk và quyết định cho từng dòng có dáng tiêu đề, kiểm rằng bản thô chưa bị đọc lại trong lúc dựng, rồi mới ghi bản ghi chung của cây, *sau cùng*; khi xoá thì nó đi *trước*. Nhờ vậy, thấy bản ghi chung là thấy cả cây. Chỉ sau đó job mới gửi kết quả sẵn sàng về `ingest`. Một job dựng cây bị chạy lại khi cây của đúng bản thô hiện tại đã ghi xong thì chỉ gửi lại kết quả ấy, không dựng lại.

7.3.4 Các ràng buộc và cơ chế kiểm soát

Bảng 7.10 tổng hợp các ràng buộc `document` giữ, cơ chế thực thi mỗi ràng buộc, và cách kiểm chứng.

Bảng 7.10: Ràng buộc `document` giữ, cơ chế thực thi, và cách kiểm chứng

Ràng buộc	Cơ chế thực thi	Kiểm chứng
Phân quyền		
Không có quyền vào database	Mã nguồn không nhắc tới thư viện hay thông tin kết nối database nào	`check_contract`
Mỗi thư viện bên ngoài chỉ được dùng thẳng ở đúng một tệp: object store, đọc PDF, content store, Jev, mô hình ngôn ngữ	`storage`, `pdf`, `content_store`, `index/jev`, `index/llm`	`check_contract`
Chỉ `document` ghi content store; `backend` chỉ đọc	`agent` và `ingest` không dùng thư viện của content store; tệp duy nhất của `backend` dùng nó không gọi hàm ghi nào	`check_contract`
Tính nhất quán		
Kết quả sẵn sàng chỉ được gửi sau khi bản thô và cây đã ghi	Thứ tự trong hai worker	kiểm thử tự động
Bản ghi chung của cây ghi sau cùng, xoá đầu tiên	`content_store`	kiểm thử tự động
Tài liệu bị đọc lại (chỉ khi job dò tệp chạy lại) thì cây cũ bị xoá	`content_store`	kiểm thử tự động
Tệp hay trang không đọc nổi, cây không dựng được, content store hay `redis` hỏng tới lần thử cuối: mỗi ca thành một kết quả kèm lý do	Ba hàm nhận job, trong `ocr_handlers` và `index_handlers`	kiểm thử tự động
Điều khiển đồng thời		
Worker đọc tệp chạy một job một lúc	Cấu hình worker	kiểm thử tự động
Một cuốn chỉ có một chuỗi lô và một job dựng cây	Mã cố định của job	kiểm thử tự động
Thời gian		
Job tự dừng trước khi chạm trần thời gian của worker	Lô OCR không mở trang mới sau 90 giây, dưới trần 120 giây; job dựng cây tự cắt ở 540 giây, dưới trần 600 giây	kiểm thử tự động

Ràng buộc thời gian được kiểm chứng hẹp hơn lời của nó, ở hai chỗ. Khác phép kiểm của `agent`, không gì so mốc tự dừng của một job với trần thời gian của worker chạy nó: hạ trần trong cấu hình worker xuống dưới mốc ấy cũng không làm kiểm thử nào đỏ. Và lô OCR chỉ

xem đồng hồ sau khi đọc xong một trang, nên một trang đọc lâu hơn ba mươi giây vẫn đẩy được cả lô quá trần. Ngoài bảng, việc `document` không nhận lời gọi nào từ bên ngoài đứng được nhờ hình dạng của nó: hai worker chỉ lấy job từ queue. Điều ấy chỉ được ghi trong luật của service; không gì chặn một lượt sửa sau thêm vào đó một máy chủ HTTP.

7.3.5 Xử lý lỗi

Các worker chạy trên thư viện arq, và arq chỉ chạy lại một job khi job ấy chủ động xin; một job chạm trần thời gian thì bị giết mà không ai báo gì. Vì vậy mọi cách hỏng của `document` phải tự biến thành một kết quả (bảng 7.11). Cột cuối nói giáo viên thấy gì: khi có lỗi, dòng trạng thái của tài liệu in "Xử lí lỗi. Hãy tải lại", và lý do hiện khi trỏ chuột vào nó. Một tệp hỏng hay không có chữ thì không nằm trong bảng: đó là một kết quả bình thường của việc dò tệp.

Bảng 7.11: Khi một thao tác bên trong `document` hỏng, và giáo viên thấy gì

Khi	`document` làm gì	Giáo viên thấy
Content store, object store và `redis`		
Content store hay `redis` trục trặc	Xin chạy lại: tối đa năm lần chạy kể cả lần đầu, bốn khoảng nghỉ cộng lại 50 giây; lần thứ năm vẫn hỏng thì gửi kết quả hỏng	Đang xử lý, rồi lỗi: "Kho lưu trữ đang trục trặc nên chưa xử lý xong tệp. Thử tải lại sau."
Không đọc được tệp từ object store	Lúc dò tệp: gửi kết quả hỏng ngay, không chạy lại. Giữa chuỗi lô: xin chạy lại như hàng trên	Lỗi: "Chưa đọc được tệp đã cất. Thử lại sau."
Đọc tệp		
Một trang không đọc nổi giữa một lô	Gửi kết quả hỏng, nói rõ trang nào	Lỗi: "Không đọc được trang n của tệp PDF này."
Một lô chạy quá lâu	Không mở trang mới sau 90 giây, rồi giao phần còn lại cho lô kế; một trang chậm vẫn có thể đẩy lô quá trần 120 giây, và khi ấy job bị giết	Thường không thấy gì; job bị giết thì như hàng cuối
Dựng cây		
Jev hay một mô hình hỏng, hay chưa được cấu hình	Hàm ấy đi đường lùi của nó (bảng 7.9)	Không thấy gì; cây kém hơn
Job dựng cây chạy quá lâu	Tự cắt ở 540 giây, dưới trần 600 giây, rồi gửi kết quả hỏng kèm lý do	Lỗi, như hàng dưới

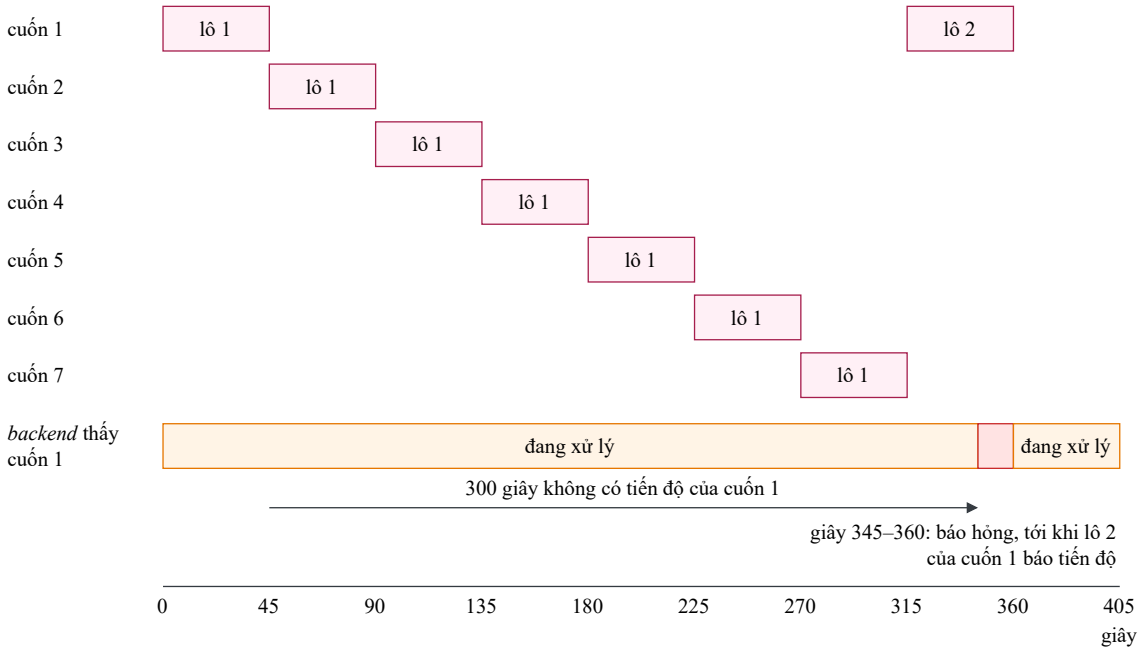
tiếp trang sau

Khi	`document` làm gì	Giáo viên thấy
Một lỗi bất ngờ khác khi dựng cây	Gửi kết quả hỏng	Lỗi: "Đã đọc được chữ nhưng chưa dựng được mục lục. Thử tải lại tệp."
Tài liệu bị đọc lại giữa lúc dựng cây	Lần đọc mới đã xong thì xin chạy lại trên bản mới; còn đang đọc thì dừng, không gửi gì, và lần đọc mới, khi xong, sẽ giao lại job dựng cây	Thường không thấy gì; job mới bị từ chối vì job cũ còn chạy thì như hàng cuối
Không có bản thô nào để dựng	Dừng, không gửi gì	Như hàng cuối
Khi `document` không báo được gì		
Không báo gì quá 300 giây: job bị giết, hay `redis` chết ở lần thử cuối	`backend` đọc tài liệu ra là hỏng	Lỗi: "Xử lý tài liệu này đã dừng giữa đường. Thử tải lại."

7.3.6 Các giới hạn hiện tại

Bốn yêu cầu dưới đây đã được đặt ra cho hệ thống, nhưng `document` mới thực thi một phần. Mỗi yêu cầu có một chỗ hở cụ thể:

- **Một tài liệu đang đọc không bị báo hỏng oan** — worker đọc tệp chạy một job một lúc, nên nhiều bản chụp tải lên cùng lúc được đọc xen kẽ từng lô, và ngay một lần dò tệp có sẵn chữ cũng phải xếp sau các lô ấy. Mỗi lô mất chừng bốn mươi lăm giây, tới chín mươi giây nếu trang dày chữ, nên hai lần báo tiến độ của một cuốn cách nhau chừng ấy nhân với số cuốn đang đọc. Từ chừng bảy cuốn, hay bốn cuốn nếu trang dày chữ, khoảng cách ấy vượt ba trăm giây và `backend` đọc cuốn ấy ra là hỏng. Lỗi ấy tự hết khi lô kế của cuốn báo tiến độ, nhưng trong lúc đó giáo viên đọc "Hãy tải lại". Hình 7.9 vẽ trường hợp bảy cuốn.



Hình 7.9: Báo hỏng oan: bảy cuốn đọc xen kẽ từng lô, mỗi lô chừng bốn mươi lăm giây

- **Cây mục lục đúng với cuốn sách** — ở ngưỡng hiện tại, trên cuốn duy nhất có mục lục chuẩn để so, Jev chưa làm đổi nút nào của cây, nên cây của cuốn ấy chính là cây của luật. Cả luật lẫn ngưỡng đều được chỉnh trên chính cuốn ấy, và luật còn mang mẫu riêng của một bộ sách giáo khoa, nên phép so Jev với luật chưa công bằng. Một lỗi đã gặp: trên cuốn Toán 10 tập 1, nút "Chương IV. VECTƠ" trỏ vào các trang của chương I, nên một đề "phần vectơ" ra tám câu về mệnh đề và tập hợp.
- **Đọc trọn chữ của bản chụp** — công thức chỉ có chữ OCR, và khối bảng không nhận chữ nào. Hướng đã chọn là đọc công thức lúc ra đề, chỉ ở phần tài liệu được dùng, bằng một mô hình đọc ảnh; đường ấy chưa được viết.
- **Giáo viên biết khi cây kém hơn** — bản ghi chung của cây ghi cây được xếp bằng Jev hay chỉ bằng luật, mô hình tóm tắt và mô hình đọc tên chương có được cấu hình không, và bao nhiêu dòng Jev không đủ chắc. Nhưng không đoạn mã nào của `backend` hay `agent` đọc những trường ấy, nên giáo viên không được báo; còn một mô hình hỏng lúc chạy thì bản ghi chung không ghi lại.

Tài liệu tham khảo

Báo cáo này mô tả một hệ thống đang chạy được, nên nguồn của nó là chính mã nguồn và các bản ghi quyết định đi kèm, chứ không phải tài liệu bên ngoài. Mọi con số và mọi luật nêu trong báo cáo đều có một chỗ tương ứng trong kho dưới đây.

Mã nguồn và tài liệu kỹ thuật của dự án
`https://github.com/biabeogo147/AI-Assessment-and-Feedback-Assistant`

Kho chứa năm **service** (thành phần) đã mô tả ở chương 6, mà ba trong số đó được đi vào bên trong ở chương 7, cùng ba nhóm tài liệu mà báo cáo này rút gọn từ đó:

- `docs/decisions/` — các bản ghi quyết định nghiệp vụ. Mỗi quyết định ở đó ghi cả phần *đã cân nhắc những gì* và *nơi nào thi hành nó*, hai phần mà báo cáo này không đưa vào.
- `docs/overview/` — mô tả nghiệp vụ, kiến trúc và mô hình dữ liệu. Nguồn của chương 4, 5, 6 và 7.
- `docs/diagrams/` — tệp gốc của mọi sơ đồ trong báo cáo. Các hình ở đây được *xuất ra* từ chúng chứ không vẽ lại, và một phép kiểm tự động trong kho sẽ báo đỏ nếu một sơ đồ đổi mà hình chưa xuất lại.

Các luật được canh bằng máy
`tools/check_contract.py` và `AGENTS.md` trong kho trên.